“Hito 2 - Avance intermedio”

Autores: *Barrionuevo Zoe, Corona Narella, Duelli Martín, Kremer Chiara, Lonardi Paula, Viganoni Victoria*

Tutor: *Peralta Iván*

Consigna: realizar pruebas con la base de datos y comenzar el análisis sobre un número reducido de muestras. Este documento presenta el sistema propuesto, su fundamento teórico y los resultados de una primera prueba con 8 señales de PTDB-TUG.

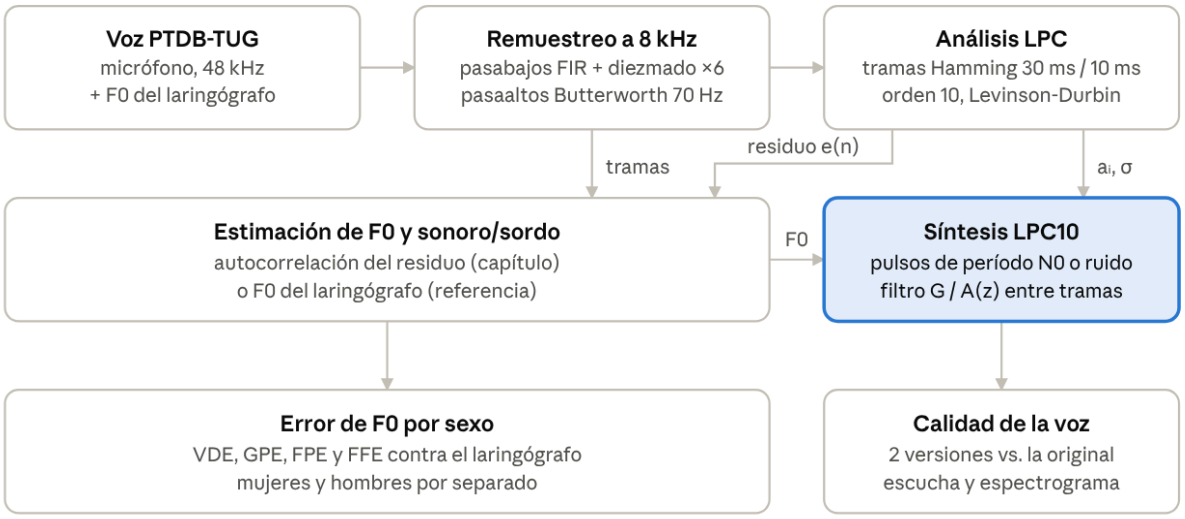
Problema elegido: *Evaluación de métodos de estimación de pitch y clasificación sonoro/sordo en la codificación de voz LPC10*

Actividades realizadas:

Entre la devolución del Hito 1 y esta entrega, el grupo implementó la base del sistema y la probó con señales reales.

1. Organización del trabajo: se creó un repositorio en GitHub con el código, las minutas de reunión, los resúmenes teóricos.
2. Implementación del análisis-síntesis LPC10: se tradujo a Python el codificador de la sección 1.2.6 del capítulo de referencia (Dutoit et al., 2009), agregando el remuestreo de 48 a 8 kHz que exige la base de datos.
3. Primera prueba: se procesaron 8 señales de PTDB-TUG (2 mujeres y 2 hombres, frases sa1 y sa2 de cada uno) y se comparó la F0 estimada con la del laringógrafo.
4. Puesta en común: todos los integrantes revisaron el código y las figuras, y las dudas surgidas se resolvieron en la reunión con el tutor.

Diagrama de bloques



El sistema toma la voz del micrófono de PTDB-TUG, la lleva a calidad telefónica, la codifica con LPC10 y evalúa la F0 estimada por dos caminos: contra el laringógrafo y por la calidad de la voz resintetizada.

1. Preprocesamiento. La señal se remuestrea de 48 a 8 kHz con un filtro pasabajos FIR antialiasing seguido de un diezmado por 6. Luego se aplica un pasaaltos Butterworth de orden 4 con corte en 70 Hz.
2. Análisis LPC. La señal se divide en tramas de 30 ms (240 muestras) con salto de 10 ms y ventana de Hamming. En cada trama, un análisis LPC de orden 10 estima el filtro del tracto vocal (coeficientes a_i y ganancia σ). Al filtrar la trama con A(z) se obtiene el residuo e(n).
3. Estimación de F0 y decisión sonoro/sordo. El estimador del capítulo busca el máximo de la autocorrelación del residuo. Como caso de referencia se usa la F0 del laringógrafo.
4. Síntesis LPC10. Con la F0 de cada trama, el decodificador genera un tren de pulsos de período N0 (trama sonora) o ruido blanco (trama sorda) y lo filtra por G/A(z), manteniendo el estado del filtro entre tramas.
5. Evaluación. La F0 se compara con la del laringógrafo mediante VDE, GPE, FPE y FFE, separando mujeres y hombres. La voz sintetizada con cada F0 se compara con la original por escucha y espectrograma.

Justificación teórica

Modelo fuente-filtro: LPC10 modela la voz como una excitación (pulsos periódicos o ruido) que pasa por un filtro todo-polos 1/A(z) que representa el tracto vocal (Dutoit et al., 2009; Rabiner y Schafer, 2011). Cada par de polos complejos conjugados cercano al círculo

unitario produce un pico en la envolvente espectral, es decir, un formante. Con orden 10 a 8 kHz se dispone de 5 pares de polos, suficientes para representar los formantes de la banda telefónica.

Cálculo de los coeficientes: Los coeficientes a_i minimizan el error de predicción y se obtienen resolviendo las ecuaciones de Yule-Walker con el algoritmo de Levinson-Durbin. Se verificó que la implementación propia coincide con un solver de matrices Toeplitz.

Residuo y pitch: Al filtrar la voz por A(z) se elimina la envolvente espectral y queda un residuo de espectro casi plano que conserva la periodicidad de la excitación. Por eso el máximo de su autocorrelación, buscado entre 60 y 400 Hz, indica el período T0. La decisión sonoro/sordo compara ese máximo con la energía del residuo: si el cociente supera 0,25, la trama es sonora. El umbral no figura en el capítulo y se eligió con las 8 señales de esta prueba.

Remuestreo: El capítulo trabaja a 8 kHz y PTDB-TUG está a 48 kHz. Diezmar por 6 sin filtrar plegaría el contenido entre 4 y 24 kHz sobre la banda útil (aliasing), por lo que se filtra antes con corte en 4 kHz (scipy.signal.resample_poly). El pasaaltos de 70 Hz elimina el ruido de baja frecuencia del silencio inicial de las grabaciones, que el estimador confundía con voz.

Métricas: Se usan las métricas habituales de evaluación de pitch:

- VDE: porcentaje de tramas con decisión sonoro/sordo distinta a la del laringógrafo.
- GPE: entre las tramas sonoras para ambos, porcentaje con error relativo mayor al 20%.
- FPE: desvío estándar del error relativo en las tramas sin error grueso.
- FFE: porcentaje de tramas con error de decisión o error grueso (Chu y Alwan, 2009).

Métodos de comparación: Siguiendo la sugerencia del tutor, el estimador del capítulo se comparará con el cepstrum y con YIN manteniendo LPC10 como sistema base.

Resultados preliminares

El estimador del capítulo sigue bien la F0 del laringógrafo: el error fino ronda el 2% y el error grueso es bajo. Su principal debilidad es la decisión sonoro/sordo en voces masculinas, donde el VDE duplica al de las femeninas.

Los resultados se pueden ver tabulados en el código dentro del repositorio.

- Puntos atípicos: algunas tramas quedan lejos de la referencia (por ejemplo, el GPE de 12% en F02 sa2). Por acuerdo con el tutor, no se corrigen, ya que forman parte del error propio del método que se busca evaluar.
- Espectrograma: aparecen componentes aisladas en frecuencias altas. Para determinar su origen se agregará el espectrograma intermedio, después del filtro antialiasing.
- Calidad de la voz: la síntesis con la F0 del laringógrafo funciona como la mejor calidad alcanzable con LPC10, y permite separar el efecto de los errores de pitch de las limitaciones propias del modelo.

Base de datos y código

Se usa PTDB-TUG (Pirker et al., 2011), de licencia abierta (ODbL). Incluye 20 hablantes nativos de inglés, 10 mujeres y 10 hombres de 22 a 48 años, con 4720 grabaciones en total. Cada frase está grabada a 48 kHz y 16 bits con micrófono y laringógrafo simultáneamente, y trae una F0 de referencia cada 10 ms calculada sobre la señal del laringógrafo. Esa referencia objetiva es la que permite medir el error de cada estimador.

El código está en el repositorio del grupo, en el notebook 01_primera_prueba_LPC10.

Próximos pasos

- Extender la evaluación a los 20 hablantes de la base, reportando media, desvío y curvas de variación de cada error.
- Revisar el umbral sonoro/sordo con más datos y comparar con el análisis actual.
- Redactar el informe en formato correspondiente, incluyendo el código.

Referencias

Chu, W. y Alwan, A. (2009). Reducing F0 frame error of F0 tracking algorithms under noisy conditions with an unvoiced/voiced classification frontend. Proc. ICASSP, 3969–3972.

de Cheveigné, A. y Kawahara, H. (2002). YIN, a fundamental frequency estimator for speech and music. JASA, 111(4), 1917–1930.

Dutoit, T., Moreau, N. y Kroon, P. (2009). How is speech processed in a cell phone conversation? En T. Dutoit y F. Marqués (eds.), Applied Signal Processing: A MATLAB-Based Proof of Concept, cap. 1. Springer.

Noll, A. M. (1967). Cepstrum pitch determination. JASA, 41(2), 293–309.

Pirker, G., Wohlmayr, M., Petrik, S. y Pernkopf, F. (2011). A pitch tracking corpus with evaluation on multipitch tracking scenario. Proc. Interspeech, 1509–1512.

Rabiner, L. y Schafer, R. (2011). Theory and Applications of Digital Speech Processing. Pearson.