“Hito 3 - Prototipo funcional”

Autores: *Barrionuevo Zoe, Corona Narella, Duelli Martín, Kremer Chiara, Lonardi Paula, Viganoni Victoria*

Tutor: *Peralta Iván*

Consigna: presentar un prototipo funcional en Python capaz de cargar las señales, procesarlas (filtros y transformadas) y mostrar resultados preliminares, con gráficos de entrada contra salida y espectros, para revisar el código con el tutor antes de la defensa final.

Problema elegido: *Evaluación de métodos de estimación de pitch y clasificación sonoro/sordo en la codificación de voz LPC10.*

Actividades realizadas:

Entre la entrega del hito 2 y ésta entrega, se completó el sistema y se lo evaluó sobre toda la base de datos.

El prototipo de la entrega es el notebook 03_evaluacion_base_completa.ipynb.

1. Comparación de estimadores: al método del capítulo (autocorrelación del residuo LPC) se sumaron el cepstrum real (Noll, 1967) y YIN (de Cheveigné y Kawahara, 2002), siguiendo la sugerencia del tutor. Los tres trabajan sobre las mismas tramas del codificador LPC10.
2. Calibración de umbrales: el umbral sonoro/sordo de cada método se eligió con 40 grabaciones separadas de las de evaluación, minimizando el FFE. En el Hito 2 el umbral del capítulo (0,25) se había elegido con las mismas 8 señales de prueba; con la calibración separada volvió a resultar 0,25, y los de cepstrum y YIN quedaron en 0,16 y 0,30.
3. Evaluación sobre la base completa: se procesaron las 4678 grabaciones restantes de PTDB-TUG, reportando VDE, GPE y FPE por sexo y por hablante, con test de Wilcoxon y análisis de errores de octava.
4. Síntesis con cada estimador: cada F0 se incorporó al decodificador LPC10 y se generó una biblioteca de 400 audios (80 grabaciones × 5 versiones) para comparar al oído, incluida la versión con la F0 del laringógrafo.
5. Respuesta a las dudas del Hito 2: se agregaron espectrogramas en cada etapa de la cadena (original, después del antialias, después del pasaaltos y salida del LPC10) con la misma escala en dB. La atenuación del ruido viene sobre todo del pasaaltos de 70 Hz (la SNR sube unos 5 dB, porque el 58 % de la energía del ruido de silencio

está por debajo de 70 Hz) y no de la decisión sonoro/sordo del LPC10 (aporta 1,4 dB).

6. Puesta en común: los resultados y los audios se revisaron entre todos los integrantes.

Procesamiento implementado (filtros y transformadas):

- Remuestreo de 48 a 8 kHz con pasabajos FIR antialiasing y diezmado por 6 (scipy.signal.resample_poly).
- Pasaaltos Butterworth de orden 4 con corte en 70 Hz (scipy.signal.butter y lfilter).
- Análisis LPC de orden 10 en tramas de 30 ms con salto de 10 ms y ventana de Hamming, con Levinson-Durbin propio verificado contra scipy.linalg.solve_toeplitz.
- Filtrado inverso por A(z) para obtener el residuo, y síntesis por G/A(z) conservando el estado del filtro entre tramas.
- Estimadores de F0: autocorrelación del residuo (capítulo), cepstrum real con DFT de 512 puntos y YIN con función diferencia normalizada e interpolación parabólica. Los tres buscan F0 entre 60 y 400 Hz.
- Espectrogramas de banda ancha (ventana de 5 ms) en cada etapa de la cadena.

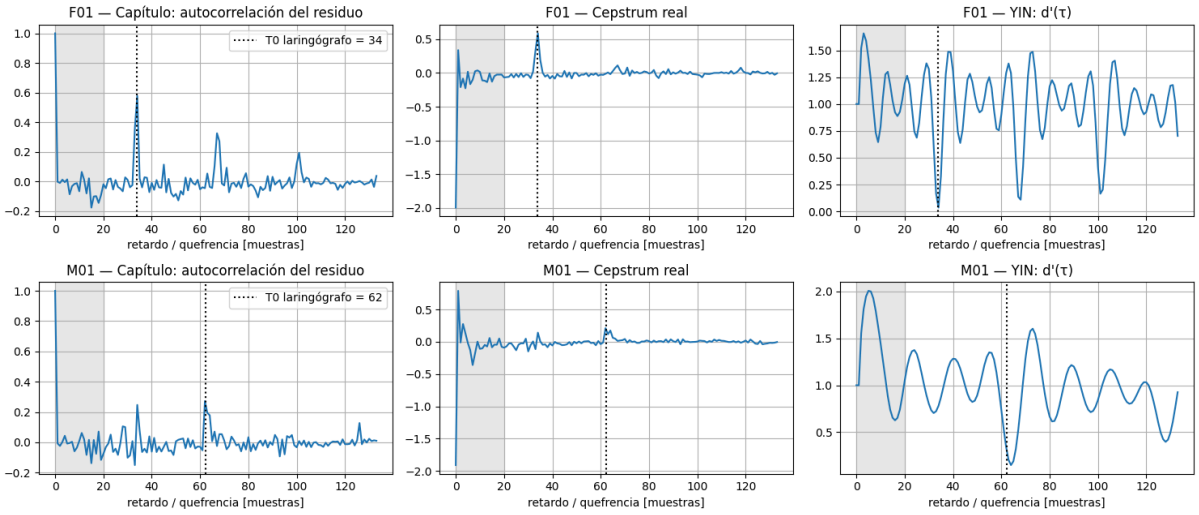


Figura 1. Función en la que cada estimador busca el período, en una trama sonora de una mujer (F01, arriba) y de un hombre (M01, abajo). La línea punteada es el T0 del laringógrafo. Notebook 02.

Resultados preliminares

YIN es el que mejor decide si una trama es sonora o sorda, sobre todo en hombres; el cepstrum es el que comete menos errores gruesos; el método del capítulo no gana en ninguna métrica.

Entrada contra salida. Los espectrogramas por etapa muestran que el remuestreo elimina todo lo que está por encima de 4 kHz sin afectar la voz, y que el pasaaltos quita el ruido de muy baja frecuencia del silencio inicial. La salida del LPC10 conserva la envolvente formántica de la entrada, pero reemplaza la estructura armónica fina por pulsos ideales.

Método	VDE mujeres / hombres	GPE mujeres / hombres	FPE mujeres / hombres
Capítulo	6,8 / 11,9 %	3,8 / 1,7 %	1,9 / 2,1 %
Cepstrum	6,4 / 12,3 %	**2,8 / 0,8 %**	1,9 / 2,1 %
YIN	**5,8 / 7,2 %**	4,0 / 1,7 %	**1,5 / 1,6 %**

Las diferencias se repiten hablante por hablante: YIN tiene menor VDE que el capítulo en 19 de 20 hablantes y menor FPE en 20 de 20, y el cepstrum menor GPE que el capítulo en 20 de 20 (test de Wilcoxon, $p < 0{,}001$). Respecto del Hito 2 se confirma la debilidad del método del capítulo en voces masculinas: su VDE crece a medida que baja la F0 del hablante (correlación de Spearman de −0,88).

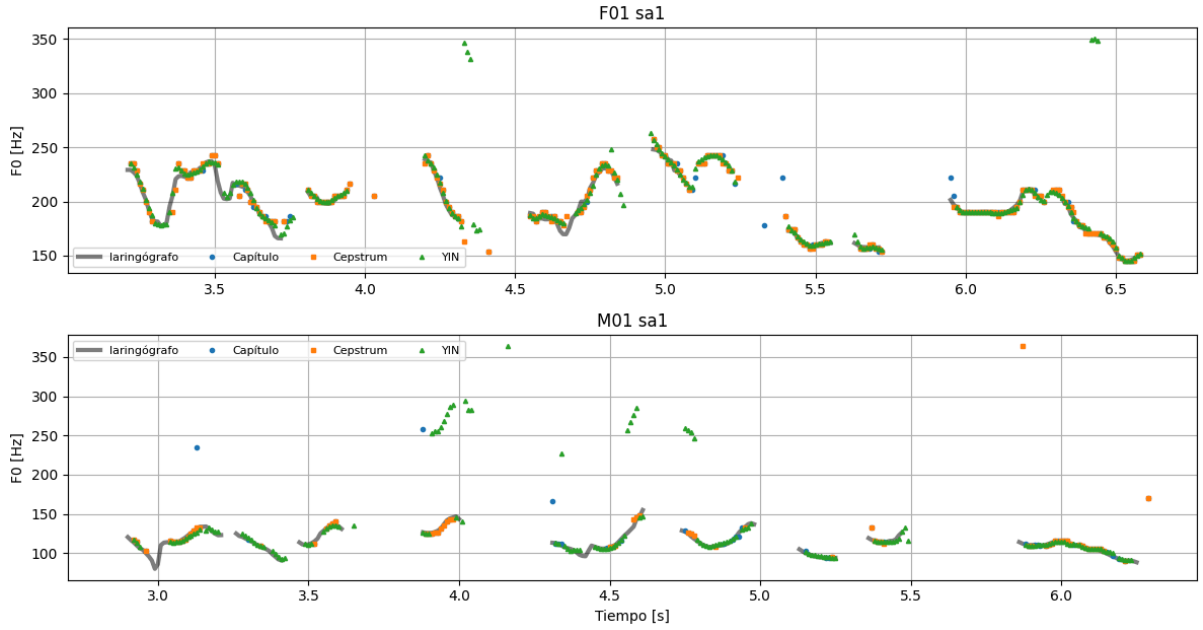


Figura 2. Contornos de F0 de la frase sa1 en F01 y M01: los tres métodos siguen al laringógrafo (gris); los puntos aislados son errores gruesos. Notebook 02.

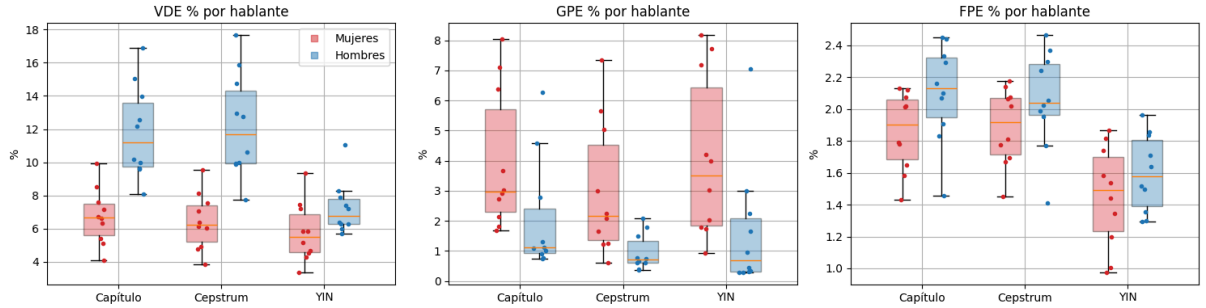


Figura 3. Error de cada hablante por método y sexo (un punto por hablante). YIN reduce el VDE de los hombres y su dispersión. Notebook 03.

Errores de octava: En mujeres, el método del capítulo reparte sus errores gruesos casi por igual entre octava arriba (42 %), que es la que advierte el capítulo, y octava abajo (45 %).

YIN, en cambio, se equivoca casi siempre hacia arriba (71 % en mujeres y 81 % en hombres).

Voz resintetizada: Las versiones con los tres estimadores y con la F0 del laringógrafo suenan muy parecidas y en todas se entiende la frase. Con YIN la entonación parece levemente más natural. Lo que domina el sonido es el timbre robótico propio del LPC10, igual en las cuatro, lo que sugiere que la calidad está limitada por el modelo de excitación y no por el estimador.

Próximos pasos

- Terminar el informe final para la entrega del 10 de noviembre.
- Preparar la presentación oral (15 a 20 minutos) con los gráficos y una selección de audios de la biblioteca.
- Repasar entre todos cada bloque del sistema para la defensa individual.

Referencias

Chu, W. y Alwan, A. (2009). Reducing F0 frame error of F0 tracking algorithms under noisy conditions with an unvoiced/voiced classification frontend. Proc. ICASSP, 3969–3972.

de Cheveigné, A. y Kawahara, H. (2002). YIN, a fundamental frequency estimator for speech and music. JASA, 111(4), 1917–1930.

Dutoit, T., Moreau, N. y Kroon, P. (2009). How is speech processed in a cell phone conversation? En T. Dutoit y F. Marqués (eds.), Applied Signal Processing: A MATLAB-Based Proof of Concept, cap. 1. Springer.

Noll, A. M. (1967). Cepstrum pitch determination. JASA, 41(2), 293–309.

Pirker, G., Wohlmayr, M., Petrik, S. y Pernkopf, F. (2011). A pitch tracking corpus with evaluation on multipitch tracking scenario. Proc. Interspeech, 1509–1512.

Rabiner, L. y Schafer, R. (2011). Theory and Applications of Digital Speech Processing. Pearson.