UNER Facultad de Ingeniería

EVALUACIÓN DE MÉTODOS DE ESTIMACIÓN DE PITCH Y CLASIFICACIÓN SONORO/SORDO EN LA CODIFICACIÓN DE VOZ LPC10

Trabajo Práctico Integrador / Informe Final

Señales y Sistemas

Grupo 3

Autor/es: Barrionuevo, Zoe; Corona, Narella; Duelli, Martín Alejandro; Groglio Kremer, Chiara; Lonardi, Paula; Viganoni Victoria.

Tutor: Peralta Iván.

Carrera: Bioingeniería.

Fecha de entrega: 10 de noviembre.

Resumen

La codificación predictiva lineal (LPC) a bajas tasas de bits, como el estándar NATO LPC10, depende críticamente del modelado de la excitación del tracto vocal a partir de dos parámetros elementales: la estimación de la frecuencia fundamental (F_0 o pitch) y la clasificación de las tramas temporales en sonoras o sordas (V/UV). Errores en estos parámetros degradan severamente la inteligibilidad y naturalidad del habla sintetizada, provocando artefactos acústicos como estridencia o confusión de F_0 con armónicos formánticos. En este trabajo se implementa un sistema completo de análisis y síntesis de voz basado en LPC10 ($p = 10$) sobre señales diezmadas a 8 kHz, y se evalúa de manera comparativa el desempeño de tres métodos de estimación de pitch y voicing: la autocorrelación del residuo LPC, el análisis cepstral y el algoritmo YIN.

Como patrón de referencia objetiva, se utiliza la base de datos abierta PTDB-TUG, procesando las señales de laringógrafo (EGG) sincronizadas temporalmente con la voz acústica. La exactitud de los estimadores se cuantifica estadísticamente mediante el Error Grueso de Pitch (GPE), el Error Fino de Pitch (FPE) y las tasas de error de clasificación V/UV, reportando los valores en términos de media (μ) y desviación estándar (σ) discriminados según el sexo de los hablantes. Finalmente, se sintetizan las señales de audio empleando los parámetros estimados por cada método y la referencia laringográfica, analizando mediante espectrogramas y evaluación perceptual de calidad el impacto diferencial que cada tipo de error de excitación introduce en el sistema de síntesis.

1. Introducción

El habla humana constituye uno de los medios fundamentales de comunicación, representando una señal acústica compleja no estacionaria cuya dinámica temporal y frecuencial transporta tanto información lingüística como rasgos biométricos del locutor. Desde el enfoque del procesamiento de señales, el análisis y la codificación de la voz persiguen dos propósitos esenciales: reducir la redundancia para lograr una transmisión y almacenamiento eficientes a través de canales con ancho de banda limitado, y parametrizar componentes fundamentales de la producción del habla para su posterior manipulación o reconocimiento.

En este contexto, el modelo fuente-filtro (Fant, 1960) ofrece un marco teórico sumamente robusto al desacoplar el mecanismo de producción vocal en dos subsistemas independientes. Por un lado, la fuente de excitación describe la señal acústica generada en la glotis, la cual es cuasi periódica en fonemas sonoros (*voiced*) debido a la vibración

regular de los pliegues vocales a una frecuencia fundamental F_0 (período de *pitch* T_0), o bien de naturaleza turbulenta y estocástica en fonemas sordos (*unvoiced*). Por otro lado, el filtro del tracto vocal modela la función de transferencia de las cavidades resonantes (faringe, cavidad oral y nasal), modulando espectralmente dicha excitación y dando lugar a las frecuencias formánticas distintivas de cada sonido.

Bajo este principio opera el estándar clásico LPC10 (Linear Predictive Coding de orden 10), el cual parametriza el tracto vocal mediante un filtro todo-polos estimado trama a trama a partir de ecuaciones de predicción lineal (algoritmo de Levinson-Durbin), limitando el espectro al canal telefónico (frecuencia de muestreo de 8 kHz). No obstante, el principal cuello de botella en la inteligibilidad, naturalidad y calidad perceptual de este esquema de síntesis radica en la correcta estimación de los parámetros de excitación: la decisión de sonoridad (V/UV) y el cálculo preciso de F_0. Errores en esta etapa, tales como la duplicación o división del período (errores de octava) o la inserción de zumbidos metálicos por falsos positivos sonoros, degradan sustancialmente la señal reconstruida.

1.1 Objetivos

El objetivo general de este trabajo consiste en implementar computacionalmente un sistema completo de análisis y síntesis de voz basado en el estándar LPC10, y evaluar de forma comparativa la precisión de diferentes métodos para el modelado de la fuente de excitación vocal.

Como objetivos específicos, se plantean:

1. Implementar el codificador y sintetizador LPC10 ($p = 10$) sobre señales diezmadas a 8 kHz mediante el algoritmo de Levinson-Durbin.
2. Calibrar y evaluar tres estimadores de frecuencia fundamental y decisión de sonoridad: la autocorrelación del residuo LPC, la detección de periodicidad en quefrencia mediante el cepstrum real y el algoritmo YIN basado en la función de diferencia normalizada acumulada.
3. Cuantificar el desempeño temporal y frecuencial de cada estimador frente a la referencia objetiva provista por las señales de laringógrafo (EGG) de la base PTDB-TUG, utilizando métricas normalizadas de error grueso (GPE), error fino (FPE) y decisiones de sonoridad (VDE).
4. Analizar el impacto perceptual y espectrográfico que cada tipo de error de estimación introduce en la inteligibilidad y naturalidad del habla resintetizada.

2. Marco teórico

2.1 La comunicación hablada

La voz es la señal biológica de la comunicación humana. Como todo sistema de comunicación, tiene un emisor, un canal y un receptor (Milone y Rufiner, 2003). Un codificador de voz como el LPC10 se inserta en el canal, y su diseño aprovecha cómo funcionan los otros dos eslabones.

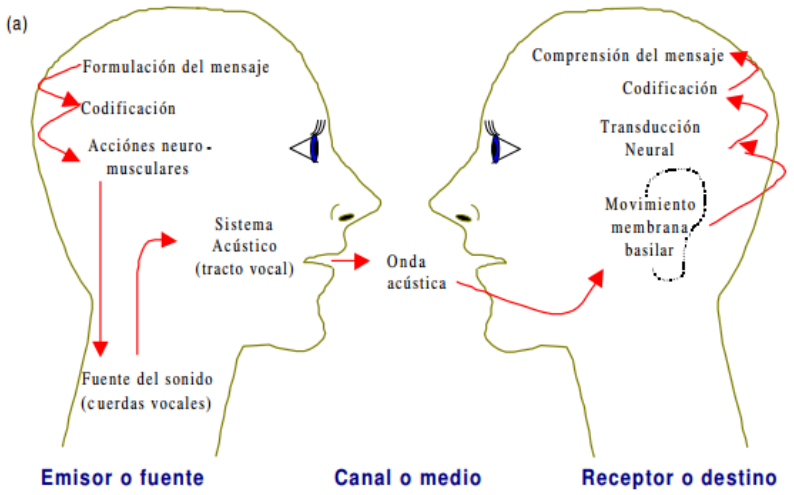


Figura 1. Cadena de la comunicación hablada, de Milone y Rufiner (2003, fig. 1.10)

LPC10 imita la cadena del habla: transmite fuente y filtro, no la onda.

Producción (emisor): el mensaje se formula en el cerebro y se convierte en órdenes neuromusculares para los órganos del habla. El sistema respiratorio es la fuente de energía: los pulmones actúan como un pistón que genera una corriente de aire. En la laringe, los pliegues vocales actúan como una válvula. Si vibran, cortan el flujo en pulsos periódicos (sonidos sonoros); si quedan abiertos, el aire pasa y se vuelve turbulento en alguna constricción del tracto (sonidos sordos). La frecuencia de vibración es F0: en la base usada en este trabajo, 111 Hz de media en hombres y 191 Hz en mujeres.

El tracto vocal, entre la glotis y los labios, mide unos 17 cm en un adulto y funciona como un tubo resonante. La lengua, los labios, la mandíbula y el velo del paladar cambian su forma y, con ella, sus resonancias: los formantes. El velo del paladar, además, acopla o no la cavidad nasal. Cada fonema queda definido por el tipo de fuente (periódica o ruidosa) y por la forma del tracto (los formantes).

Transmisión (canal): lo que sale por la boca y la nariz es una onda de presión que viaja por el aire. La voz tiene energía hasta más de 8 kHz, pero la mayor parte de la información necesaria para entenderla está por debajo de 4 kHz. Por eso la telefonía limita la banda y muestrea a 8 kHz, como en este trabajo. Un codificador paramétrico no transmite la onda:

transmite los parámetros de la fuente (F0, decisión V/UV, ganancia) y del filtro (coeficientes LPC), y el receptor reconstruye la señal. Así elimina la redundancia de la señal, que es el objetivo de la codificación de fuente (Milone y Rufiner, 2003).

Percepción (receptor): el oído externo capta la onda y el canal auditivo la conduce al tímpano. En el oído medio, los huesecillos (martillo, yunque y estribo) adaptan la impedancia entre el aire y el líquido de la cóclea. En el oído interno, la membrana basilar vibra en distinto lugar según la frecuencia: cerca de la base para las agudas y cerca del ápice para las graves. Funciona como un banco de filtros que descompone el sonido en frecuencia. Las células ciliadas convierten esa vibración en impulsos del nervio auditivo, y la corteza auditiva los interpreta como mensaje (Rabiner y Schafer, 2011).

Esto importa para el LPC10, porque tres propiedades de la audición hacen viable un códec tan simple:

- El oído analiza la señal en frecuencia y es poco sensible a la fase, por eso alcanza con reproducir la envolvente del espectro (los formantes) y la estructura armónica, sin conservar la forma de onda (Dutoit et al., 2009). El LPC10 descarta la fase y la voz sigue siendo inteligible.
- La altura tonal se percibe a partir de los armónicos, una voz masculina de 100 Hz se sigue oyendo con su tono aunque la banda telefónica corte esa frecuencia. Lo que el oyente necesita es que los pulsos lleguen con el período correcto; de ahí que los errores de F0 se perciban como entonación alterada.
- El oído distingue la periodicidad de ruido, una trama sonora sintetizada como ruido suena susurrada, y una sorda sintetizada con pulsos suena metálica. Por eso la decisión sonoro/sordo es crítica para la naturalidad.

Estas propiedades conectan los resultados objetivos de este trabajo (VDE, GPE, FPE) con lo que efectivamente oye una persona: la evaluación de un estimador de pitch tiene sentido en la medida en que sus errores sean audibles.

Finalmente proponemos el sistema como un diagrama en bloques de la cadena de comunicación, en la que se resalta el funcionamiento del LPC10, es decir de nuestro trabajo.



Figura 2: Diagrama de la cadena de la comunicación hablada. En celeste los roles que cumple el LPC10.

2.2. Modelo fuente-filtro y producción de voz

El modelo clásico de producción de habla introducido por Fant (1960) asume que la generación del sonido vocal se puede desacoplar conceptualmente en dos subsistemas independientes: la fuente de excitación glótica y el filtro del tracto vocal (Milone et al., 2005).

Mecanismo fisiológico: vibración de cuerdas vocales vs. flujo turbulento:

- *Sonoro (Voiced):* la presión de aire subglótica fuerza la apertura y cierre periódico de los pliegues vocales (Fant, 1970). Esto produce trenes de impulsos periódicos a una frecuencia fundamental F_0 o período fundamental $T_0 = 1/F_0$ (Oppenheim & Schafer, 2000; Deller et al., 1993).
- *Sordo (Unvoiced):* los pliegues vocales permanecen abiertos y relajados sin vibrar (Fant, 1970). El sonido proviene de la turbulencia generada por el paso del aire en constricciones del tracto vocal, modelándose como un proceso estocástico blanco (Deller et al., 1993; Milone et al., 2005).

<u>Representación en tiempo discreto</u>

La señal de habla discreta $s[n]$ se expresa como la convolución entre la secuencia de excitación glótica $e[n]$ y la respuesta al impulso del tracto vocal $h[n]$,

$$s[n] = e[n] * h[n] \quad \leftrightarrow \quad S(z) = E(z)H(z)$$

(Oppenheim & Schafer, 2000). El desacoplo permite parametrizar y procesar separadamente el timbre fonético y la entonación (Milone et al., 2005).

2.3. Codificación por Predicción Lineal (LPC)

La Codificación por Predicción Lineal (LPC) es una técnica paramétrica de procesamiento discreto de señales que modela la transferencia del tracto vocal mediante un filtro digital autorregresivo (AR) todo-polos. Su principio fundamental establece que cada muestra actual de una señal de habla se puede estimar como una combinación lineal ponderada de un número reducido de sus muestras anteriores.

En el dominio de la frecuencia, el filtro del tracto vocal se aproxima considerando únicamente polos. Estos representan físicamente las frecuencias de resonancia de las cavidades del aparato fonador, las *formantes*. Los coeficientes del predictor lineal ponderan las muestras pasadas para moldear la envolvente espectral de la señal. La diferencia entre la señal de voz real y la estimada constituye el residuo o error de predicción.

Los coeficientes óptimos del predictor se obtienen minimizando la energía cuadrática media de este error. Este criterio genera el sistema de ecuaciones de Yule-Walker (o Wiener-Hopf), el cual vincula directamente los coeficientes del filtro con la función de autocorrelación discreta de la voz.

Como la matriz de autocorrelación obtenida en el proceso es simétrica, el sistema se resuelve mediante el algoritmo recursivo de Levinson-Durbin. Este algoritmo calcula eficientemente los coeficientes en cada orden p y determina la ganancia adecuada para igualar la energía entre la voz original y la resintetizada.

Ver ecuaciones de la sección 2 de metodología experimental: Informe Final

Dado que la voz es no estacionaria pero cuasi-estacionaria en tramos breves de 20 a 30 ms, la señal se analiza por tramas multiplicadas por una ventana suave (como la ventana de Hamming) para atenuar discontinuidades de borde.
Para señales muestreadas a $f_s = 8kHz$ (ancho de banda telefónico de $4kHz$), la regla de diseño acústico asigna 2 polos por cada kHz de ancho de banda para representar adecuadamente las 4 formantes espectrales principales (8 polos), cada par de polos complejos conjugados cerca del círculo unitario produce un pico en la envolvente espectral, un formante. Añadiendo 2 polos adicionales para modelar la caída del espectro glótico y la radiación en los labios, se justifica la adopción del orden estándar $p = 10$ en LPC10.

2.4. Estándar NATO LPC-10

El sintetizador opera mediante un conmutador binario gobernado por la decisión sonoro/sordo (V/UV):

- Segmentos sonoros (V): la excitación se genera como un tren de impulsos cuasi-periódicos espaciados por el período fundamental T_0.

- Segmentos sordos (UV): la excitación conmuta hacia una fuente de ruido blanco aleatorio con media cero y distribución gaussiana. Dicha excitación es escalada por la ganancia G y filtrada por el sintetizador todo-polos $1/A_p(z)$ para reconstruir la señal.

Parámetros cuantizados y limitaciones intrínsecas del modelo de excitación binario

Por cada trama de 22,5 ms se transmiten 54 bits (7 para pitch y V/UV, 5 para la ganancia y 42 para los coeficientes), se cuantiza y transmite un vector compuesto por 10 coeficientes del filtro (transformados a relaciones de área logarítmicas o LAR), la ganancia G, la decisión binaria V/UV y el período de pitch T_0, logrando bajas tasas de transmisión ($\approx 2.4kbps$).

Su principal desventaja, limitación del trabajo, es su rigidez. Al imponer una excitación exclusivamente periódica o puramente ruidosa, no logra representar con naturalidad fonemas mixtos (como fricativas sonoras /z/ o /v/) ni transiciones fonéticas. Esto introduce un timbre sintético, robótico o metálico (*buzziness*) y reduce la expresividad perceptual de la voz.

2.5. Métodos de Estimación de Frecuencia Fundamental (F_0) y Voicing

La estimación de la frecuencia fundamental (F_0) y la decisión de sonoridad (V/UV) determinan la calidad del generador de excitación en el vocoder LPC10. Para evaluar su desempeño, se consideran tres algoritmos basados en distintos principios de procesamiento de señales:

Autocorrelación del residuo LPC

El filtrado inverso mediante los coeficientes de predicción lineal elimina la envolvente del espectro asociada a los formantes del tracto vocal, obteniéndose una señal de residuo aplanada. La función de autocorrelación sobre este residuo exhibe picos marcados en el retardo temporal equivalente al período fundamental T_0. La presencia de un pico que supera un umbral prefijado determina la condición de trama sonora (V), mientras que su ausencia indica una trama sorda (UV).

Análisis Cepstral

Se fundamenta en el procesamiento homomórfico, aplicando la transformada inversa de Fourier al logaritmo del módulo de la transformada de la señal. Esta operación desacopla la convolución del modelo fuente-filtro en una suma dentro del dominio de las quefrencias. Como resultado, las resonancias lentas del tracto vocal quedan confinadas en las bajas quefrencias, mientras que la periodicidad rápida de la fuente glótica genera un pico distintivo en altas quefrencias, cuya ubicación permite extraer F_0 y definir el estado de sonoridad.

Algoritmo YIN

Este método perfecciona la autocorrelación temporal al sustituirla por una función de diferencia promedio normalizada acumulativa. Al buscar el primer mínimo relativo que cae por debajo de un umbral absoluto, YIN previene los errores de octava (duplicación o división del período verdadero) habituales en voces agudas o tramos cuasi-periódicos, resolviendo simultáneamente la clasificación V/UV.

2.6. Laringografía (EGG)

La electroglotografía (EGG) o laringografía mide las variaciones de impedancia eléctrica a través del tejido cervical mediante un par de electrodos colocados externamente en el cuello, a la altura de la laringe. Durante la fase sonora de la fonación, el contacto físico entre los pliegues vocales aumenta la conductancia eléctrica, reduciendo la impedancia registrada. En la fase de apertura glótica, la separación de los pliegues eleva la impedancia.

Dado que la señal EGG captura directamente el movimiento mecánico fisiológico de los pliegues vocales sin ser alterada por los picos formánticos del tracto vocal ni por el ruido de la transmisión acústica, la derivada temporal de esta señal ($d(EGG)/dt$) permite identificar con precisión absoluta los instantes de cierre glótico (GCI). Por este motivo, constituye la referencia objetiva fundamental (*ground truth*) para evaluar y calibrar la exactitud de los estimadores acústicos de F_0.

3. Proceso metodológico

El trabajo se organizó a partir de distintos roles definidos por cada integrante,con los entregables de cada hito, consultas con el tutor y registro de decisiones en un repositorio.

3.1 Roles

Integrante	Rol	Responsabilidad
María Victoria Viganoni	Coordinadora	Organizó las reuniones, canalizó la comunicación con el tutor y mantuvo el foco semanal
Martín Duelli	Responsable técnico (Lead coder)	Estructura del código en Python, repositorio y buenas prácticas
Paula Lonardi	Documentadora (Scribe)	Minutas, búsqueda bibliográfica, redacción de

		entregables y documentación de reuniones.
Zoe Barrionuevo, Narella Corona, Chiara Groglio Kremer	Integrantes	Participación de todas las actividades con énfasis en lluvia de ideas, revisión del código y redacción del informe

3.2 Cronología de hitos, reuniones y consultas con el tutor

Fecha	Instancia	Resultados
18/10/2026	Reunión 1: lluvia de ideas y asignación de roles	5 líneas de trabajo: tos, sonidos respiratorios, geometría del tracto vocal por LPC, separación de componentes de la voz, disfonías (CPP)
19/10/2026	Reunión 2: consulta con el tutor	Las propuestas no estaban acotadas al marco del proyecto. Se reorienta el trabajo a la codificación y decodificación de voz del capítulo de Dutoit et al.
Semana 11	Hito 1: 3 ideas-problema	Estimación de pitch y V/UV para LPC10; voz sonora a partir de susurro; preservación de características vocales
25/10/2026	Devolución del tutor por correo	Se valida la propuesta de pitch y V/UV, con lineamientos: LPC10 de la sección 1.2.6, comparación con cepstrum y YIN, métricas por sexo, caso de referencia con el laringógrafo, remuestreo con antialiasing
25/10/2026	Reunión 3: primera prueba	Repositorio creado; LPC10 sobre 8 señales; revisión conjunta del código; preguntas para el tutor
26/10/2026	Consulta con el tutor	Polos y formantes, ruido en el espectrograma (agregar espectrograma intermedio), los valores atípicos no se corrigen porque son parte del error del método

Semana 12	Hito 2: propuesta de implementación	Diagrama de bloques, justificación teórica, base de datos y resultados preliminares
26/10 al 31/10/2026	Desarrollo	Comparación de los tres estimadores (200 grabaciones) y evaluación sobre la base completa
Semana 14	Hito 3: prototipo funcional	Notebooks ejecutables con resultados y audios resintetizados
Semana 15	Hito 4: defensa final	Presentación oral y defensa individual

3.3 Gestión del código y de la documentación

El código se versionó en GitHub con commits pequeños y descriptivos. El repositorio guarda las minutas (docs/reuniones/), los entregables de cada hito (docs/hitos/), los resúmenes teóricos (docs/teoria/), el registro de uso de IA (docs/ia/), los notebooks y los resultados (results/). Los documentos de trabajo se compartieron en una carpeta de Google Drive vinculada al repositorio.

METODOLOGÍA EXPERIMENTAL

La metodología desarrollada se divide en cuatro etapas secuenciales: el preprocesamiento de las señales acústicas y laringográficas, la formulación del codificador y sintetizador LPC10, la implementación y calibración de los tres estimadores de excitación (F_0 y decisión V/UV), y la definición de las métricas de evaluación objetiva y subjetiva.

1.1 Base de datos PTDB-TUG

Se utilizó la base de datos abierta *Pitch Tracking Database from Graz University of Technology* (PTDB-TUG), la cual provee un patrón de referencia objetivo (*ground truth*) riguroso mediante el registro sincronizado de:

- Señal acústica de voz capturada por micrófono de alta calidad ($F_s = 48kHz$).
- Señal de laringógrafo (electroglotografía, EGG), que mide la impedancia eléctrica a través de los pliegues vocales ($F_s = 48kHz$).

El corpus comprende 20 hablantes nativos de inglés (10 masculinos y 10 femeninos) leyendo textos fonéticamente balanceados (oraciones TIMIT). Para este trabajo se dispuso de 4678 grabaciones de evaluación independiente y un subconjunto de 40 grabaciones reservadas exclusivamente para la etapa de desarrollo y calibración de umbrales.

1.2 Acondicionamiento de señal

Para emular el canal telefónico bajo el estándar LPC10, la señal acústica se remuestrea a $F_s = 8kHz$ previa aplicación de un filtro antialiasing paso-bajos. La referencia de pitch del laringógrafo no requiere remuestreo, ya que PTDB-TUG la provee como una secuencia de valores de f_0 cada 10 ms, coincidente con el salto de análisis de 80 muestras.

A continuación, la señal s[n] se filtra con un paso-altos Butterworth de orden 4 con frecuencia de corte de 70 Hz. Este filtro elimina la componente continua, el zumbido de red (50 Hz) y el ruido de baja frecuencia propio de la grabación, que de otro modo incrementarían los primeros valores de la autocorrelación y sesgarían tanto la estimación de los coeficientes LPC como la del período de pitch.

La señal se divide en tramas temporales de $30ms$ ($N = 240$ muestras a 8 kHz) con un desplazamiento de trama de $10ms$ ($H = 80$ muestras, 66,7% de solapamiento), ponderadas por una ventana de Hamming $w[n]$ para mitigar la discontinuidad en los bordes:

$$s_{w,m}[n] = s[n + mH] \cdot w[n], 0 \leq n \leq N - 1$$

$$w[n] = 0,54 - 0,46\, cos(\frac{2\pi n}{N-1})$$

donde m es el índice de trama. La duración de 30 ms garantiza la cuasi-estacionariedad del tracto vocal y abarca al menos dos períodos de pitch para $f_0 \geq 67$ Hz.

2. Codificador y sintetizador LPC10

2.1 Análisis predictivo lineal

El tracto vocal se aproxima mediante un modelo autorregresivo (AR) todo-polos de orden $p = 10$:

$$S(z) = \frac{G}{A(z)} = \frac{G}{1 + \sum_{k=1}^{p} a_k z^{-k}}$$

donde el orden $p = 10$ se fundamenta en la regla empírica de ubicar aproximadamente un formante por cada kHz de ancho de banda telefónico ($2 \times 4kHz = 8$ polos) más dos polos adicionales para modelar la forma de onda glotal.

Los coeficientes óptimos $\{a_k\}$ se obtienen minimizando la energía cuadrática media del residuo de predicción:

$$e[n] = s_w[n] + \sum_{k=1}^{p} a_k s_w[n-k]$$

Igualando las derivadas parciales a cero, se arriba al sistema clásico de ecuaciones de Yule-Walker:

$$\sum_{k=1}^{p} a_k \phi_{ss}[\,|i-k|\,] = -\phi_{ss}[i], \quad i = 1,\ldots,p$$

donde $\phi_{ss}[i] = \sum_{n=0}^{N-1-i} s_w[n] s_w[n+i]$ son los coeficientes de autocorrelación muestral. Debido a la estructura de Toeplitz simétrica de la matriz, el sistema se resuelve eficientemente mediante el algoritmo recursivo de Levinson-Durbin en orden $O(p^2)$.

La ganancia G (o desviación estándar del residuo σ) se calcula a partir de la energía residual:

$$G = \sigma = \sqrt{\phi_{ss}[0] + \sum_{k=1}^{p} a_k \phi_{ss}[k]}$$

2.2 Síntesis de voz

En la etapa de síntesis, la excitación sintética $\tilde{e}[n]$ se inyecta en el filtro recursivo $H(z) = G/A(z)$:

- **Trama sonora (V):** se genera un tren de deltas de Dirac separadas por el período de pitch estimado $T_0 = F_s/F_0$ muestras. Se preserva un acumulador de fase (*pitch offset*) entre tramas adyacentes para asegurar la continuidad temporal de la vibración glotal sin truncamientos artificiales.
- **Trama sorda (UV):** se excita con ruido blanco gaussiano de media cero y varianza unitaria.
- **Memoria de filtro:** para prevenir clics y transitorios espurios en las fronteras de trama, los estados internos del filtro de síntesis z^{-1} se retienen y encadenan continuamente entre tramas sucesivas.

3. Estimadores de pitch y decisión de sonoridad (V/UV)

Se implementaron tres técnicas independientes sobre cada trama de análisis, acotando el rango de búsqueda a $F_0 \in [60, 400] Hz$ (retardos $\tau \in [20, 133]$ muestras a 8 kHz).

3.1 Autocorrelación del residuo LPC

Para eliminar la influencia de los formantes (en particular F1, cuya periodicidad puede generar picos de autocorrelación que compiten con el del período fundamental), la trama ventaneada se filtra con el filtro inverso A(z), obtenido por LPC de orden P = 10, y se obtiene el residuo de predicción e[n], de espectro aproximadamente plano:

$$e[n] = s_w[n] + \sum_{k=1}^{P} a_k s_w[n-k]$$

Sobre el residuo se calcula la autocorrelación

$$r_e[\tau] = \sum_{n=0}^{N-1-\tau} e[n]e[n+\tau]$$

El período de pitch se estima como la ubicación del máximo de r_e[τ] dentro del intervalo de búsqueda [τ_min, τ_max] = [20, 133] muestras, que corresponde a f₀ entre 60 y 400 Hz:

$$\hat{T}_0 = \arg\max_{20\le\tau\le133} r_e[\tau], \hat{F}_0 = \frac{F_s}{\hat{T}_0}$$

La trama se clasifica como sonora si el valor normalizado del pico supera un umbral θ = 0,25, calibrado en un subconjunto de frases excluido de la evaluación; en caso contrario se etiqueta como sorda (F̂₀ = 0):

$$\rho = \frac{r_e[\hat{T}_0]}{r_e[0]} > \theta$$

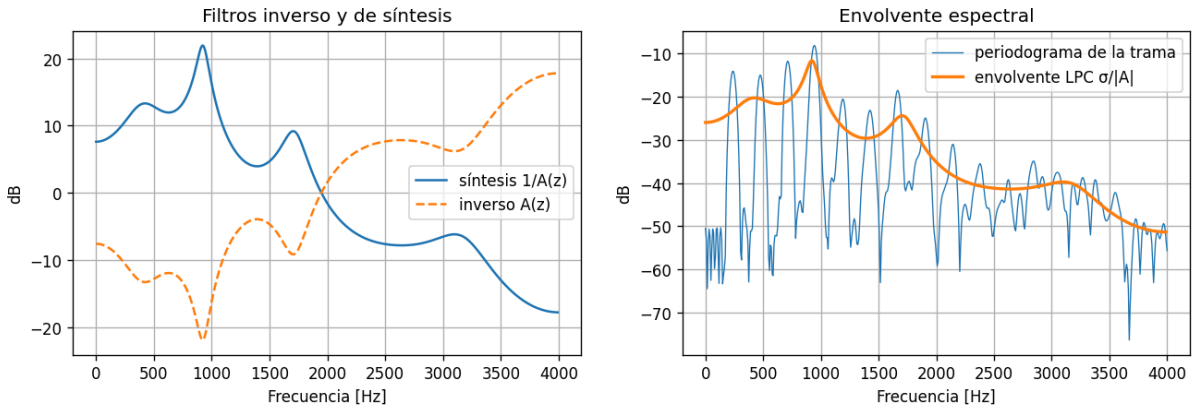


Figura 3. Izquierda: respuesta del filtro de síntesis 1/A(z) y del inverso A(z). Derecha: periodograma de una trama sonora y envolvente LPC σ/\|A\|; cada pico de la envolvente corresponde a un par de polos (formante). Fuente: notebook 01.

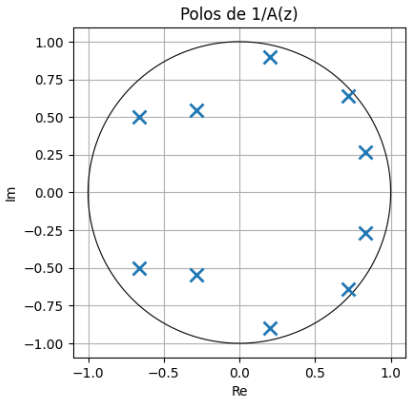


Figura 4: Polos que dan origen a cada pico de la envolvente, cada formante.

3.2 Análisis cepstral real (Cepstrum)

Aprovechando el marco de los sistemas homomórficos para deconvolución de componentes convolucionales:

$$s[n] = e[n] * h[n] \rightarrow S(z) = E(z) * H(z)$$

El cepstrum real $c_s[m]$ transforma el producto de convolución en una adición separable en el dominio de la quefrencia (m):

$$c_s[m] = F^{-1}\{log|F\{s_w[n]\}|\}$$

- Las componentes de variación lenta en el espectro (tracto vocal $H(e^{j\omega})$) quedan confinadas en las bajas quefrencias ($m < 2ms$).
- La estructura periódica fina de la glotis genera un pico armónico dominante en altas quefrencias. El retardo $\hat{\tau}_0$ se ubica detectando el valor máximo en la región de excitación $\tau \in [20, 133]$ muestras ($2,5ms$ a $16,6\,ms$). La decisión V/UV compara la amplitud del pico c_s[T̂₀] con un umbral θ_CEP = 0,16. No se requiere normalización por energía: una ganancia a en la señal solo agrega log a a todo el log-espectro, lo que afecta únicamente a c_s[0], por lo que la altura del pico cepstral es invariante a la amplitud de la señal.

3.3 Algoritmo YIN

El algoritmo YIN opera en el dominio temporal mediante las siguientes etapas formuladas para minimizar errores de duplicación de período:

1. **Función de diferencia:**

$$d[\tau] = \sum_{n=0}^{W-1} \left(s_p[n] - s_p[n + \tau]\right)^2$$

2. **Diferencia normalizada acumulativa media (CMNDF):** Evita la caída cuadrática trivial en $\tau = 0$ normalizando por el promedio de valores previos:

$$d'[\tau] = \begin{cases} 1, & \text{si } \tau = 0 \\ \frac{d[\tau]}{\frac{1}{\tau}\sum_{j=1}^{\tau} d[j]}, & \text{si } \tau > 0 \end{cases}$$

3. **Umbral absoluto y sub-interpolación:** Se selecciona el primer mínimo local donde $d'[\tau] < \theta_{YIN}$ (el artículo original sugiere 0,10 - 0,15; en este trabajo se calibró en 0,30). Si se cumple, el retardo se refina a nivel submuestral mediante interpolación parabólica centrada en el mínimo local.

4. **Decisión V/UV:** Si el valor mínimo normalizado satisface $d'[\hat{\tau}_0] < \eta_{YIN}$, la trama es sonora; en caso contrario, se decide UV.

3.4 Estimadores implementados

Los tres métodos trabajan sobre las mismas tramas del codificador y buscan T0 entre 20 y 133 muestras, es decir F0 entre 60 y 400 Hz. Cada uno devuelve un período candidato y un puntaje de periodicidad; la trama es sonora si el puntaje supera el umbral calibrado.

Método	Función	Puntaje	Umbral
Autocorrelación	Autocorrelación del residuo e(n) = A(z)·s(n)	r_e(T0) / r_e(0)	0,25
Cepstrum	Cepstrum real, DFT de 512 puntos	c(T0)	0,16
YIN	d′(τ), primer mínimo bajo el umbral, interpolación parabólica	1 − d′(T0)	d′ < 0,30

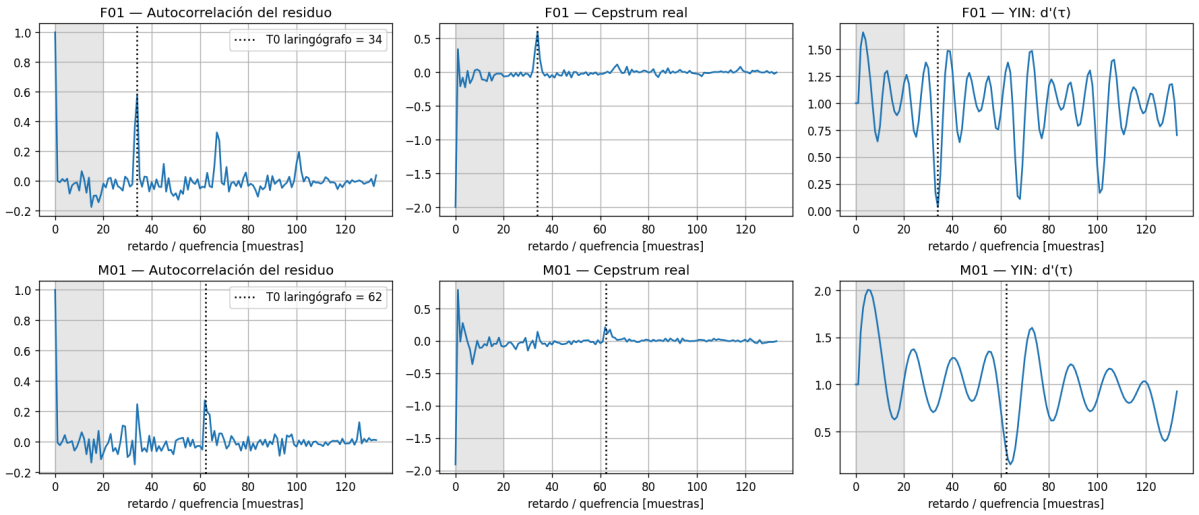


Figura 5. Función donde cada método busca T0 en una trama sonora de F01 (arriba, T0 = 34 muestras) y de M01 (abajo, T0 = 62). La línea punteada es el T0 del laringógrafo y la zona gris, los retardos fuera del rango de búsqueda. Fuente: notebook 02.

3.5. Estrategia de calibración de umbrales

Para evitar el sesgo de sobreajuste (*overfitting*), la calibración de los hiperparámetros de decisión sonora/sorda (η_{ACF}, η_{CEP}, η_{YIN}) se condujo de forma aislada en el conjunto de desarrollo de 40 archivos (20 masculinos y 20 femeninos).

Se probaron distintos valores de umbral para cada método y se eligió el que minimiza el FFE (F0 frame error, Chu y Alwan, 2009): el porcentaje de tramas con error de decisión sonoro/sordo o con error grueso de pitch. Al combinar VDE y GPE en un solo número, el umbral no favorece una métrica a costa de la otra. Los umbrales óptimos resultantes se fijaron estrictamente para la evaluación masiva sobre las 4678 grabaciones restantes.

4. Resultados

Sobre la base completa (4678 grabaciones, 3.399.028 tramas), YIN tiene el menor VDE y el menor FPE en ambos sexos, el cepstrum el menor GPE, y el método del capítulo no es el mejor en ninguna métrica.

Métricas de evaluación

La evaluación comparativa de las trayectorias de pitch estimadas ($\hat{F}_0$) contra la referencia del laringógrafo ($F_{0,ref}$) se realiza trama a trama mediante las métricas estándar de seguimiento de entonación:

- **Error grueso de Pitch (GPE - *Gross Pitch Error*):** Porcentaje de tramas sonoras donde el pitch estimado discrepa en más del 20% respecto a la referencia (captura duplicaciones y subdivisiones de período):

$$GPE = \frac{N_G}{N_{VV}} \times 100\ \%$$

donde N_{VV} es la cantidad de tramas sonoras tanto en el estimador como en la referencia, y N_G es la cantidad de esas tramas en las que $|\hat{F}_0 - F_0, ref| > 0,20 \cdot F_0, ref$.

- **Error fino de pitch (FPE, *Fine Pitch Error*):** desvío estándar del error relativo de F0 en las tramas que son sonoras tanto en el estimador como en la referencia y que no presentan error grueso ($|\hat{F}_0 - F_0, ref| \leq 0,20 \cdot F_0, ref$). Siendo C ese conjunto de tramas, M su cantidad y ε_i el error relativo de cada trama:

$$\varepsilon_i = (\hat{F}_{0,i} - F_0, ref, _i) / F_0, ref, _i, \ \bar{\varepsilon} = (1/M)\ \Sigma_\{i \in C\}\ \varepsilon_i$$

$$FPE = \sqrt{\frac{1}{M} \sum_{i \in C} (\varepsilon_i - \bar{\varepsilon})^2} \cdot 100\%$$

El FPE mide la precisión del estimador cuando acierta el período, independientemente de los errores gruesos (Chu y Alwan, 2009).

- **Error de decisión de sonoridad (VDE - *Voicing Decision Error*):** porcentaje del total de tramas en el que la decisión sonoro/sordo del estimador no coincide con la de la referencia:

$$VDE = \frac{N_{V \to UV} + N_{UV \to V}}{N_{total}} \times 100\ \%$$

donde N_V→UV es la cantidad de tramas sonoras en la referencia clasificadas como sordas, N_UV→V la de tramas sordas clasificadas como sonoras y N_{total} el total de tramas. Una trama se considera sonora en la referencia cuando su F_0,ref es mayor que cero.

- **Error global de frecuencia fundamental (FFE - *Fundamental Frequency Error*):** proporción de tramas con cualquier tipo de error, ya sea de decisión sonoro/sordo o grueso de pitch (Chu y Alwan, 2009):

$$FFE = \frac{N_{V \to UV} + N_{UV \to V} + N_G}{N_{total}} \times 100\ \%$$

donde N_V→UV y N_UV→V son las tramas sonoras clasificadas como sordas y viceversa, N_G la cantidad de errores gruesos y N_{total} el total de tramas.

Significancia estadística: para evaluar si las diferencias entre estimadores son consistentes entre hablantes, se calcularon las métricas de cada hablante y se aplicó la prueba no paramétrica de rangos con signo de Wilcoxon, emparejada por hablante, con un nivel de significancia $\alpha = 0{,}05$.

4.1. Desempeño por sexo

Tabla 1. Métricas acumuladas sobre todas las tramas de cada grupo (results/03_metricas_por_sexo_base_completa.csv). En negrita, el mejor método de cada columna.

Método	VDE mujeres [%]	VDE hombres [%]	GPE mujeres [%]	GPE hombres [%]	FPE mujeres [%]	FPE hombres [%]
Autocorrelación	6,75	11,86	3,78	1,72	1,88	2,09
Cepstrum	6,42	12,26	**2,84**	**0,83**	1,91	2,05
YIN	**5,79**	**7,22**	3,95	1,66	**1,48**	**1,59**

En total se analizaron 1.714.574 tramas de mujeres y 1.684.454 de hombres. Sólo alrededor del 23% de las tramas son sonoras según la referencia: un estimador que declarara todo sordo tendría un VDE de alrededor del 23%.

Tabla 2. Media ± desvío estándar entre los 10 hablantes de cada sexo (results/03_metricas_por_hablante.csv).

Método	VDE mujeres [%]	VDE hombres [%]	GPE mujeres [%]	GPE hombres [%]	FPE mujeres [%]	FPE hombres [%]
Autocorrelación	6,75 ± 1,70	11,82 ± 2,80	3,95 ± 2,33	2,06 ± 1,91	1,86 ± 0,25	2,10 ± 0,31
Cepstrum	6,43 ± 1,71	12,22 ± 3,14	3,01 ± 2,24	0,95 ± 0,61	1,89 ± 0,24	2,06 ± 0,31
YIN	5,77 ± 1,79	7,24 ± 1,59	4,08 ± 2,70	1,66 ± 2,12	1,45 ± 0,32	1,60 ± 0,24

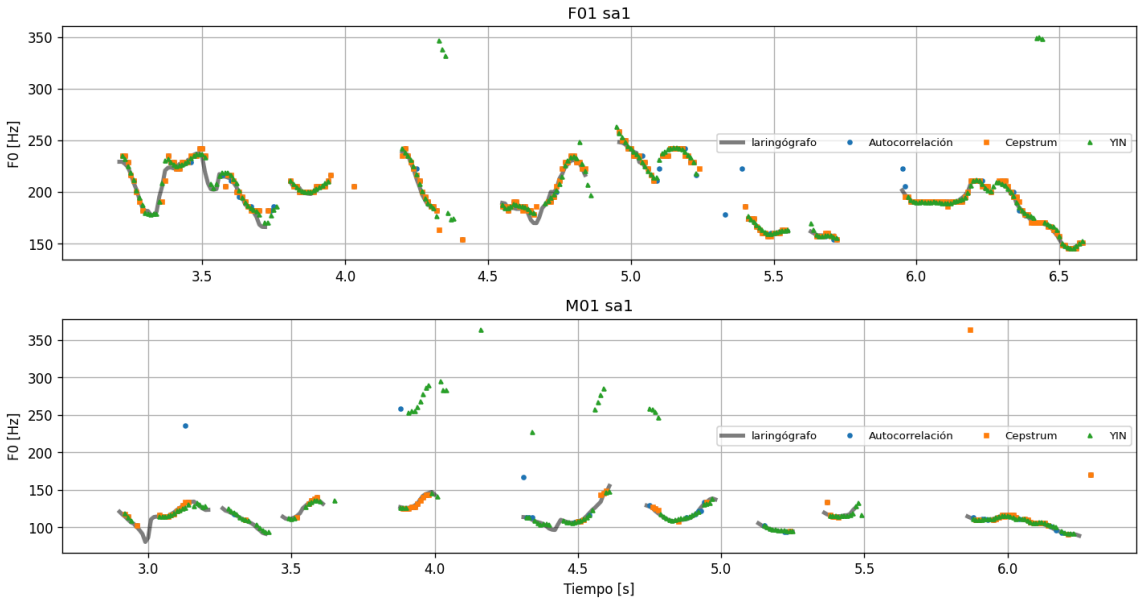


Figura 6. Contornos de F0 de la frase sa1 en F01 y M01. Los tres métodos siguen al laringógrafo; los puntos aislados lejos de la curva son errores gruesos, y los de YIN en M01 cerca de 250–350 Hz son subperíodos (octava arriba). Fuente: notebook 02.

4.2 Consistencia entre hablantes (Wilcoxon)

Tabla 3. Comparaciones sobre los 20 hablantes: filas "Todos" de results/03_wilcoxon_por_hablante.csv. El archivo tiene además las mismas comparaciones separadas por sexo. "Hablantes" = en cuántos el primer método tiene menos error.

Métrica	Comparación	Mediana de la diferencia [pp]	Hablantes	p-valor
VDE	YIN vs autocorrelación	−1,72	19/20	$2{,}7\cdot10^{-5}$
VDE	YIN vs cepstrum	−1,49	19/20	$3{,}6\cdot10^{-5}$
VDE	Cepstrum vs autocorrelación	−0,13	12/20	0,78
GPE	Cepstrum vs autocorrelación	−0,69	20/20	$1{,}9\cdot10^{-6}$
GPE	YIN vs cepstrum	+0,35	6/20	0,027
GPE	YIN vs autocorrelación	−0,23	11/20	0,99
FPE	YIN vs autocorrelación	−0,44	20/20	$1{,}9\cdot10^{-6}$
FPE	YIN vs cepstrum	−0,44	20/20	$1{,}9\cdot10^{-6}$

Métrica	Comparación	Mediana de la diferencia [pp]	Hablantes	p-valor
FPE	Cepstrum vs autocorrelación	0,00	9/20	0,52

Separando por sexo, el cepstrum decide sonoro/sordo peor que la autocorrelación en hombres (mejor sólo en 2 de 10, p = 0,02), mientras que en mujeres es mejor en 10 de 10 (p = 0,002).

La separación por sexo muestra otros dos efectos que en el total quedan ocultos. En mujeres, el método del capítulo tiene menor FPE que el cepstrum en 9 de 10 hablantes (p = 0,0098), mientras que en hombres ocurre lo contrario. También en mujeres, el cepstrum comete menos errores gruesos que YIN en 9 de 10 hablantes (p = 0,0098); en hombres esa diferencia no es significativa (p = 0,56).

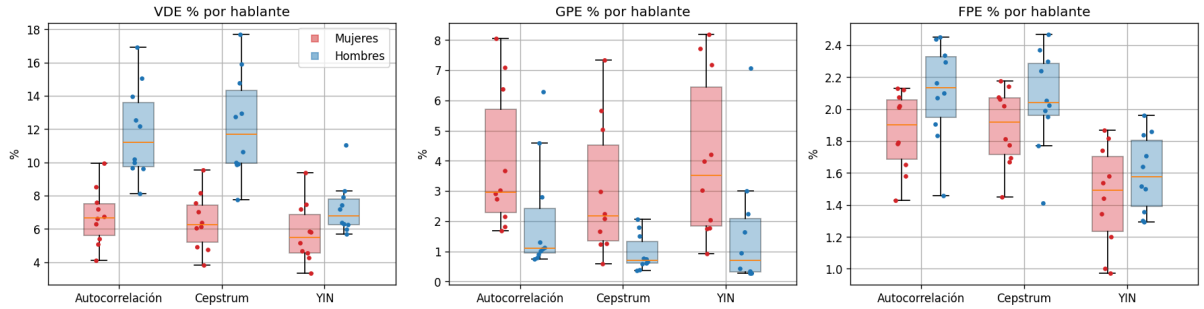


Figura 7. VDE, GPE y FPE de cada hablante (un punto por hablante) por método y sexo. YIN reduce el VDE de los hombres y su dispersión. Fuente: notebook 03.

4.3 Error en función de la F0 del hablante

Tabla 4. Correlación de Spearman entre la F0 media de cada hablante (según la referencia) y su error.

Método	VDE	GPE	FPE
Autocorrelación	−0,88	+0,34	−0,43
Cepstrum	−0,91	+0,32	−0,30
YIN	−0,52	+0,53	−0,10

Cuanto más grave la voz, más errores de decisión sonoro/sordo, sobre todo con la autocorrelación y el cepstrum. Los hablantes con mayor VDE son M02, M03 y M06 (14 a 18 % con autocorrelación y cepstrum; YIN lo baja a 6–11 %). Los mayores GPE aparecen en F06, F08 y F10 (5 a 8 % con los tres métodos).

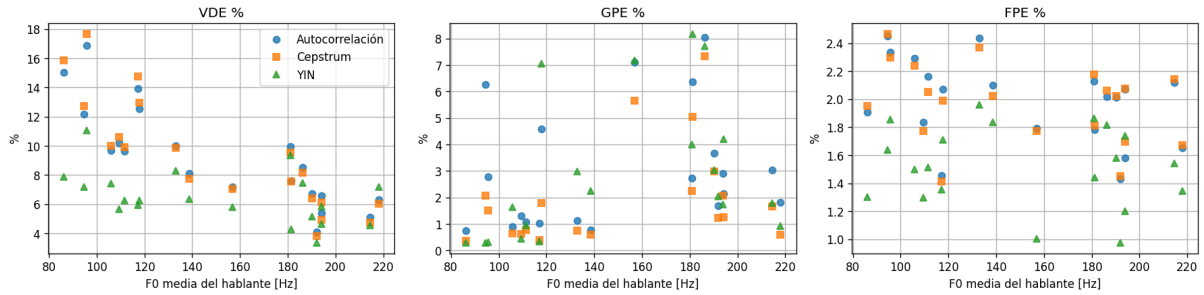


Figura 8. Error de cada método frente a la F0 media de cada hablante. El VDE de la autocorrelación y del cepstrum crece hacia las voces graves; el de YIN se mantiene más plano. Fuente: notebook 03.

4.4 Errores de octava

Tabla 5. Distribución de los errores gruesos según el cociente $\hat{F}_0/F_{0,ref}$.

Método	Grupo	Errores gruesos [tramas]	Octava arriba [%]	Octava abajo [%]	Otros [%]
Autocorrelación	Mujeres	12.573	41,9	44,6	13,5
Autocorrelación	Hombres	3.688	41,5	2,2	56,3
Cepstrum	Mujeres	9.507	50,9	33,5	15,7
Cepstrum	Hombres	1.690	33,0	3,9	63,1
YIN	Mujeres	14.442	70,8	19,3	9,9
YIN	Hombres	4.906	81,2	8,1	10,6

4.5 Voz resintetizada

Las versiones decodificadas con los tres estimadores y con la F0 del laringógrafo suenan muy parecidas, y en todas la frase se entiende. La impresión del grupo es que con YIN la entonación es levemente más natural, lo que coincide con su menor FPE y VDE. Lo que domina el sonido es el timbre robótico propio del LPC10, igual en las cuatro versiones.

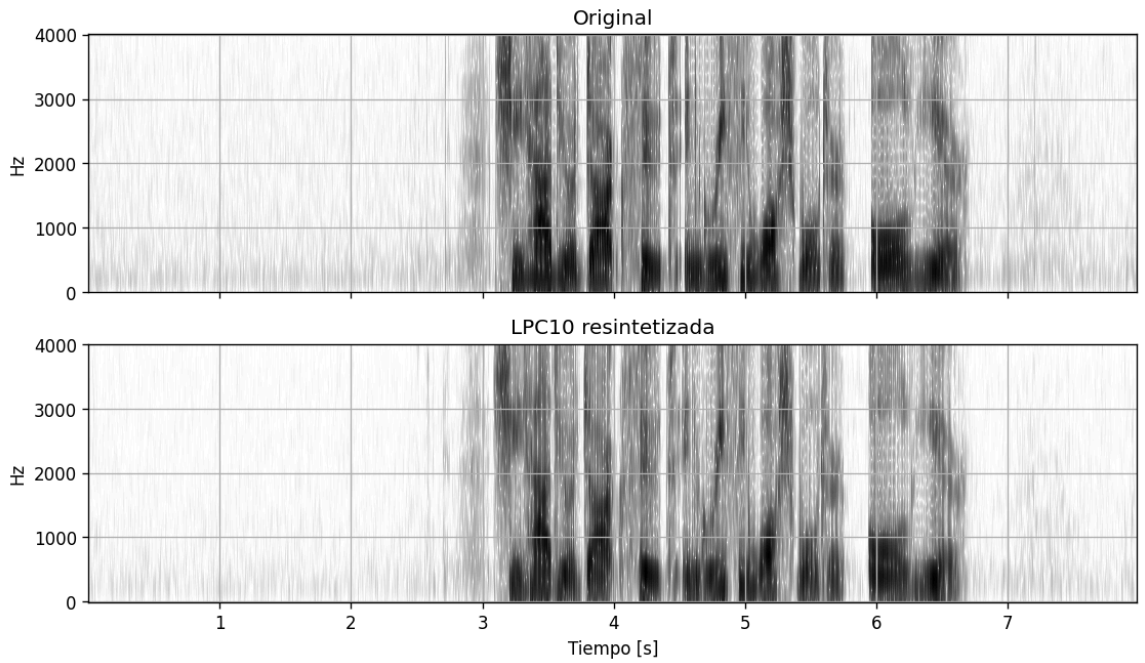


Figura 9. Espectrogramas de una frase original (a 8 kHz) y resintetizada con LPC10. La envolvente formántica se conserva; la estructura armónica fina queda reemplazada por la de los pulsos ideales. Fuente: notebook 01.

5. Discusión

Los errores no se reparten al azar: dependen de la F0 del hablante y de cómo cada método ve la periodicidad dentro de una trama de 30 ms.

5.1 Por qué las voces graves engañan a la decisión sonoro/sordo

En un hombre con F0 = 86 Hz (media de M03) el período es T0 ≈ 11,6 ms, unas 93 muestras: la trama de 30 ms contiene apenas 2,6 períodos. En los tramos más graves (p5 de 65 Hz) quedan menos de dos.

La autocorrelación del residuo se calcula sobre la trama de N = 240 muestras, así que en el retardo k sólo se superponen N − k muestras. En k = 93 se suman 147 productos y en k = 120 sólo 120, contra 240 en k = 0. El pico r_e(T0)/r_e(0) se atenúa en proporción aproximada a (N − T0)/N, aunque la señal sea perfectamente periódica. Con un umbral fijo de 0,25, una trama sonora grave tiene más chances de declararse sorda. La Figura 5 lo muestra: en F01 (T0 = 34) el pico del residuo en T0 llega a casi 0,6, mientras que en M01 (T0 = 62) apenas pasa de 0,25, justo en el umbral. Eso explica la correlación de −0,88 entre VDE y F0 en la autocorrelación.

En el cepstrum ocurre algo equivalente en frecuencia. Con F0 = 86 Hz los armónicos están separados 86 Hz, mientras que el lóbulo principal de la ventana de Hamming de 240

muestras mide unos 133 Hz. Los armónicos quedan mal resueltos, el rizado periódico de log|X| se aplana y el pico cepstral cae bajo el umbral (Spearman −0,91).

YIN, en cambio, compara siempre W = 240 muestras con su versión desplazada (por eso usa segmentos de W + 133 muestras) y normaliza por la media acumulada. El número de términos no cae con τ, así que su puntaje no se penaliza en las voces graves. Esa diferencia de formulación explica que su VDE en hombres baje de 11,9 % a 7,2 % y que la correlación con F0 se debilite a −0,52.

5.2 Errores gruesos y fisiología de la fonación

Los mayores GPE están en mujeres con tramos muy graves: F06, F08 y F10, con p5 de su F0 entre 80 y 100 Hz, cuando su media está entre 157 y 187 Hz. Esos tramos son compatibles con voz *creaky* (*vocal fry*) al final de las frases, un modo de vibración con períodos irregulares y pulsos alternados de distinta amplitud. Un estimador puede tomar como período uno de esos subciclos, o dos de ellos. El problema está en la fonación y no en el método: los tres fallan en las mismas hablantes.

El capítulo advierte que en voces femeninas el segundo armónico se confunde con F0 (octava arriba). En los datos, la autocorrelación reparte sus errores en mujeres casi por igual entre octava arriba (41,9 %) y octava abajo (44,6 %). La advertencia se cumple, pero no es el único error. Con F0 alta, T0 es corto (unas 40 muestras a 200 Hz) y 2·T0 también cae en el rango de búsqueda: en el residuo, el pico en 2·T0 puede superar al de T0 cuando los pulsos glóticos sucesivos no son idénticos.

YIN se equivoca casi siempre hacia arriba (70,8 % en mujeres y 81,2 % en hombres): elige un subperíodo. Es la consecuencia esperable de su regla, que toma el **primer** mínimo bajo el umbral para evitar la octava abajo. Con un umbral calibrado relativamente alto (0,30), un mínimo intermedio de d′(τ) producido por la estructura formántica puede aceptarse antes del verdadero T0.

5.3 Ningún método domina en todo

El cepstrum tiene el menor GPE (20 de 20 hablantes mejor que la autocorrelación) pero decide sonoro/sordo peor en hombres. YIN es el mejor en VDE y FPE, pero su GPE no difiere de la autocorrelación (p = 0,99). Para un codificador, el VDE pesa más porque las tramas mal clasificadas cambian el tipo de excitación. Además, YIN tiene una dispersión entre hablantes menor en VDE de hombres (desvío de 1,59 contra 2,80 y 3,14 puntos), lo que indica un comportamiento más estable frente a distintas voces.

5.4 La referencia tampoco es perfecta

La F0 de referencia es la salida de RAPT sobre el laringógrafo, no una medición directa de cada ciclo glótico. Aparecen valores extremos (53 y 535 Hz) que probablemente son errores de la referencia. Según lo acordado con el tutor, no se corrigieron: parte del error medido puede deberse a la referencia y no al estimador, sobre todo en los tramos *creaky*.

5.5 Qué limita la calidad del LPC10

La síntesis con la F0 del laringógrafo (pitch perfecto) suena prácticamente igual que las tres versiones estimadas. Por lo tanto, con errores de este orden (VDE de 6 a 12 %, GPE menor a 4 %), el estimador no es el cuello de botella. Lo es el modelo de excitación binario, que reemplaza la onda glótica real por impulsos ideales o ruido y no representa fonemas mixtos ni transiciones. Este resultado matiza la advertencia del capítulo: la sensibilidad del LPC10 al pitch existe, pero en condiciones de estudio queda enmascarada por su timbre robótico.

5.6 Relevancia biomédica

El laringógrafo permitió contrastar lo que “oye” un estimador acústico con lo que hacen físicamente los pliegues vocales. Los resultados muestran que los estimadores fallan justamente donde la fonación se aparta de la vibración regular: voces graves y voz *creaky*. En voces patológicas (disfonías con escape de aire, parálisis cordal) esa irregularidad es la norma, por lo que es esperable que la decisión binaria del LPC10 degrade más la voz de esos pacientes. Esto es relevante para sistemas de telemedicina o comunicación asistida que transmitan voz codificada.

6. Conclusiones

YIN es la mejor opción para el bloque de pitch y decisión sonoro/sordo del LPC10, pero la calidad final del códec está limitada por su modelo de excitación, no por el estimador.

1. Se implementó y validó en Python el análisis-síntesis LPC10 del capítulo, con remuestreo antialiasing de 48 a 8 kHz y Levinson-Durbin verificado contra un solver de Toeplitz.
2. YIN comete menos errores de decisión sonoro/sordo (VDE 5,8 % en mujeres y 7,2 % en hombres) y es el más preciso cuando acierta (FPE 1,5 % y 1,6 %). Es mejor que la autocorrelación en VDE en 19 de 20 hablantes y en FPE en 20 de 20.
3. El cepstrum es el más robusto frente a errores gruesos (GPE 2,8 % y 0,8 %, mejor que la autocorrelación en 20 de 20 hablantes), pero decide peor en voces graves.
4. El método de autocorrelación, el más simple, falla sobre todo en la decisión sonoro/sordo de voces graves. La causa es matemática: su autocorrelación se calcula sobre pocas muestras superpuestas cuando T0 es largo.

5. Los errores están ligados a la fisiología: el VDE crece al bajar la F0 del hablante y los errores gruesos se concentran en tramos de voz *creaky*.
6. La voz resintetizada con los tres métodos y con la F0 del laringógrafo es inteligible y casi indistinguible al oído.

6.1 Limitaciones

- La evaluación perceptual fue una escucha informal del grupo, sin oyentes externos ni métrica objetiva de calidad.
- La referencia (RAPT sobre el laringógrafo) tiene errores propios que no se corrigieron.
- Las grabaciones son de estudio, con micrófono cercano, habla leída y adultos sanos: representan el mejor caso. En un teléfono real (ruido, micrófono lejano) los errores serían mayores.
- Los umbrales se calibraron con 40 grabaciones y no se reajustaron por sexo.
- No se cuantizaron los parámetros, así que no se evaluó la interacción entre errores de pitch y ruido de cuantización.

Declaración de uso de inteligencia artificial

Se utilizó Claude Opus 5.5 (Anthropic), a través de Claude Code, como copiloto, dentro del uso permitido por la Guía Metodológica. Se le pidió: generar ideas de propuestas y reformularlas tras la devolución del tutor e intercambios dentro del grupo; traducir a Python el LPC10 del capítulo de Dutoit et al. e implementar cepstrum y YIN; calibrar los umbrales y analizar los métodos (VDE, GPE, FPE, Wilcoxon, Spearman); redactar borradores de textos de los notebooks y notas de reuniones; y preparar figuras para la presentación. Todo el material fue revisado por el grupo y los resultados se verificaron contra la bibliografía y los datos. El registro está en el repositorio, en docs/ia/registro-uso-ia.md.

Referencias Bibliográficas

Chu, W. y Alwan, A. (2009). Reducing F0 frame error of F0 tracking algorithms under noisy conditions with an unvoiced/voiced classification frontend. Proc. IEEE ICASSP, 3969–3972.

De Cheveigné, A. y Kawahara, H. (2002). YIN, a fundamental frequency estimator for speech and music. The Journal of the Acoustical Society of America, 111(4), 1917–1930.

Deller, J. R., Proakis, J. G. y Hansen, J. H. L. (1993). Discrete-Time Processing of Speech Signals. Macmillan.

Dutoit, T., Moreau, N. y Kroon, P. (2009). How is speech processed in a cell phone conversation? En T. Dutoit y F. Marqués (eds.), Applied Signal Processing: A MATLAB-Based Proof of Concept (cap. 1). Springer.

Fant, G. (1960). Acoustic Theory of Speech Production. Mouton.

Milone, D. H. y Rufiner, H. L. (eds.) (2003). Introducción a las señales y los sistemas discretos. Facultad de Ingeniería, Universidad Nacional de Entre Ríos.

NATO (1984). Parameters and coding characteristics that must be common to assure interoperability of 2400 bps linear predictive encoded speech (STANAG 4198, ed. 1).

Noll, A. M. (1967). Cepstrum pitch determination. The Journal of the Acoustical Society of America, 41(2), 293–309.

Oppenheim, A. V. y Schafer, R. W. (2000). Tratamiento de señales en tiempo discreto (2.ª ed.). Prentice Hall.

Pirker, G., Wohlmayr, M., Petrik, S. y Pernkopf, F. (2011). A pitch tracking corpus with evaluation on multipitch tracking scenario. Proc. Interspeech, 1509–1512.

Rabiner, L. R. y Schafer, R. W. (2011). Theory and Applications of Digital Speech Processing. Pearson.

Talkin, D. (1995). A robust algorithm for pitch tracking (RAPT). En W. B. Kleijn y K. K. Paliwal (eds.), Speech Coding and Synthesis (pp. 495–518). Elsevier.