UNER Facultad de Ingeniería

Señales y Sistemas

TRABAJO PRÁCTICO INTEGRADOR

EVALUACIÓN DE MÉTODOS DE ESTIMACIÓN DE PITCH Y CLASIFICACIÓN SONORO/SORDO EN LA CODIFICACIÓN DE VOZ LPC10

10 de noviembre de 2026

Por:

Barrionuevo Zoe, Corona Narella, Duelli Martín, Groglio Kremer Chiara, Lonardi Paula, Viganoni Victoria

Tutor:

Iván Peralta

Grupo 3

Codificación de voz

INTRODUCCIÓN

La codificación de voz permite comprimir señales para facilitar su transmisión y almacenamiento.

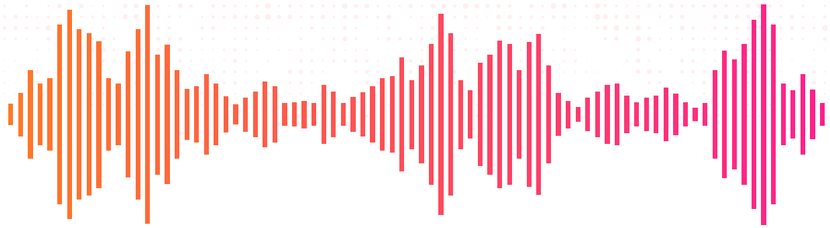

LPC10 es un sistema que permite representar y reconstruir la voz mediante un conjunto reducido de parámetros.

Estimar la frecuencia fundamental (F0 o pitch) + clasificación sonoro/sordo (V/UV).

Autocorrelación

Cepstrum

YIN

OBJETIVOS

Objetivo general

Implementar un sistema de codificación y decodificación de voz basado en LPC10, evaluando distintos métodos para estimar los parámetros necesarios para reconstruir la señal.

Objetivos específicos

- Implementar el sistema LPC10 para analizar y reconstruir señales de voz.
- Aplicar y comparar tres métodos de estimación: autocorrelación, cepstrum y YIN.
- Comparar los resultados de cada método con una señal de referencia (EGG), utilizando distintas medidas de error.
- Analizar cómo los errores de estimación afectan la calidad de la voz reconstruida.

ROLES

MARCO TEÓRICO

DIAGRAMA EN BLOQUES DE LA CADENA DE COMUNICACIÓN HABLADA

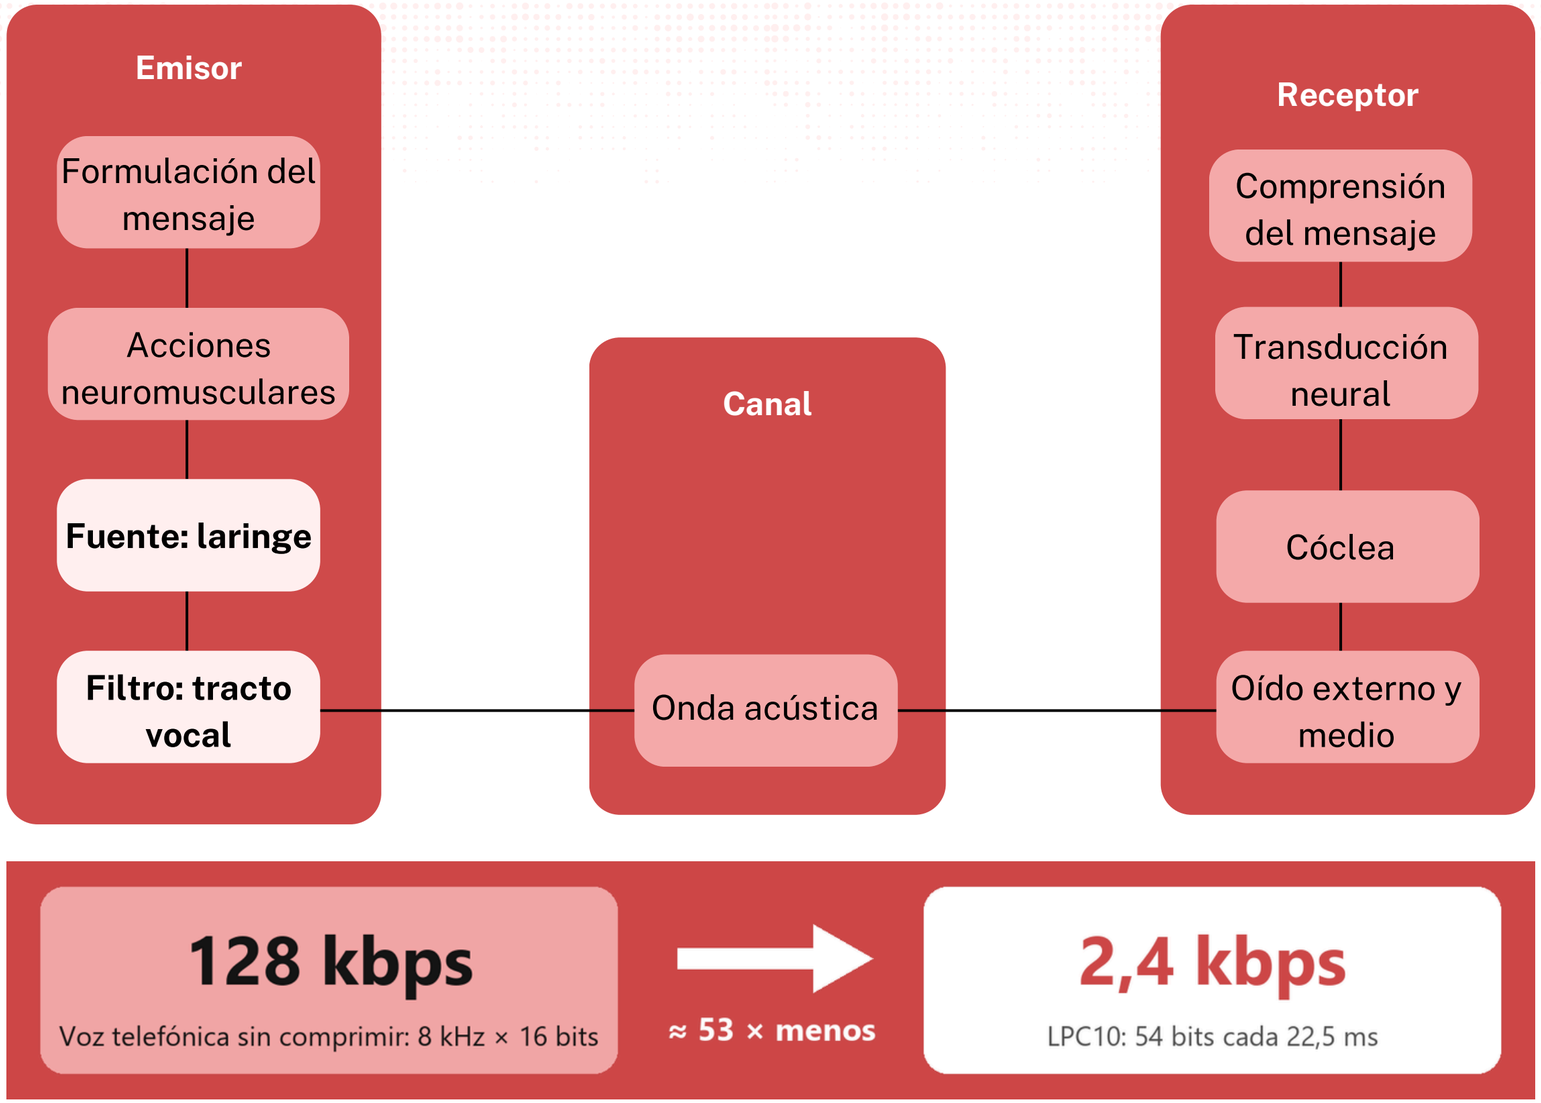

MODELO FUENTE FILTRO (FANT)

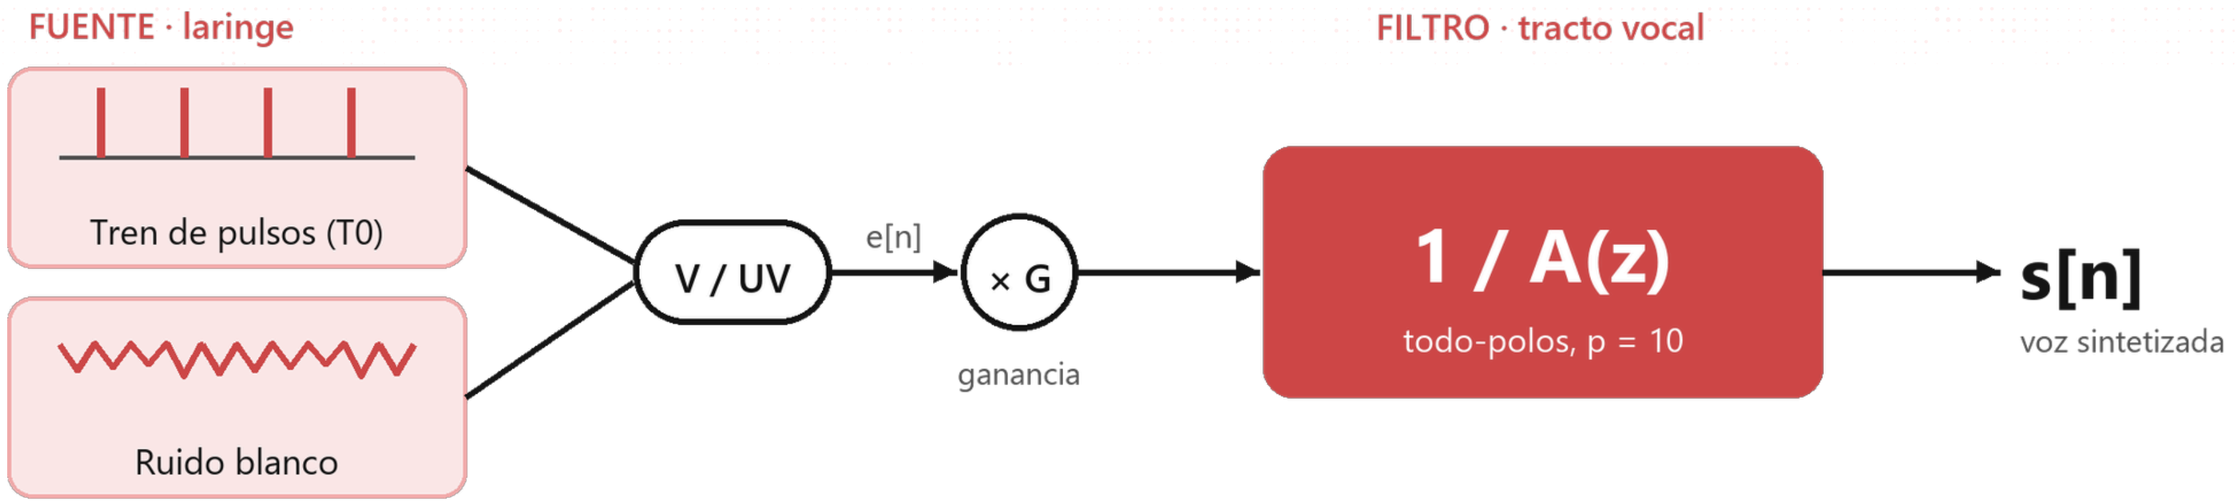

Fuente

Pliegues que vibran a F0 o aire turbulento. F0 media: 191 Hz (mujeres), 111 Hz (hombres).

Filtro

Tubo de unos 17 cm; sus resonancias (formantes) son los polos de 1/A(z).

En tiempo discreto

$s[n] = e[n] * h[n] \leftrightarrow S(z) = E(z) \cdot H(z)$

CODIFICACIÓN POR PREDICCIÓN LINEAL Y ESTÁNDAR NATO LPC10

Tracto vocal: filtro digital autorregresivo todo-polos.

$$S(z) = \frac{G}{A(z)} = \frac{G}{1 + \sum_{k=1}^{p} a_k z^{-k}}$$

¿Por qué p = 10?

4 kHz de banda → 4 formantes → 8 polos (2 por formante)
→ +2 polos (glotis y labios) = p = 10

Se transmite por cada trama (20 - 30 ms):

- 10 coeficientes del filtro
- Segmentos sonoros V
- Segmentos sordos UV
- La estimación de la frecuencia fundamental (F0).
- Ganancia

⟶ **2,4 kbps**

METODOLOGÍA EXPERIMENTAL

BASE DE DATOS PTDB-TUG

20
hablantes: 10 mujeres y 10 hombres

4718
grabaciones, 9,6 h de frases TIMIT leídas

48 kHz
micrófono y laringógrafo sincronizados

10 ms
F0 de referencia (RAPT sobre el laringógrafo)

Laringógrafo (electroglotografía)

Dos electrodos en el cuello miden la impedancia, que baja cuando los pliegues vocales se tocan. Registra la vibración sin pasar por el tracto vocal ni por el aire: es la referencia de F0.

Por qué sirve para comparar

La mujer k y el hombre k leen las mismas frases: la comparación por sexo no depende del texto. Solo el 23 % de las tramas es sonora: decir siempre “sorda” ya daría VDE ≈ 23 %.

PIPELINE

Señal de voz a 48kHz

1 Diezmado x6

48kHz → 8kHz

Filtro anti aliasing pasa-bajos (4kHz)

2 Filtro pasa-altos

Butterworth de orden 4 con fc = 70 Hz

3 Ventana Hamming

tramas de 30 ms = 240 muestras
salto de 10ms = 80 muestras

Tramas

→ Análisis LPC y pitch

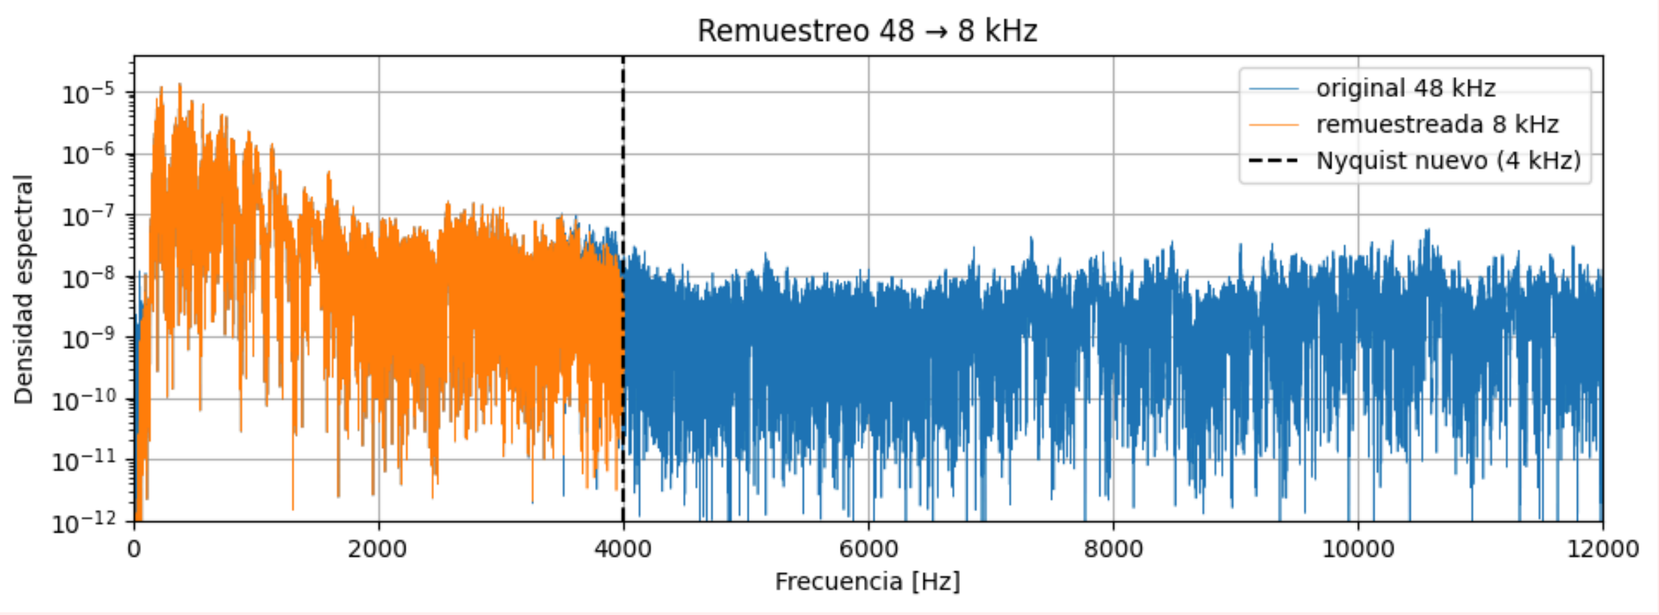

CODIFICACIÓN, SINTETIZADOR Y SÍNTESIS

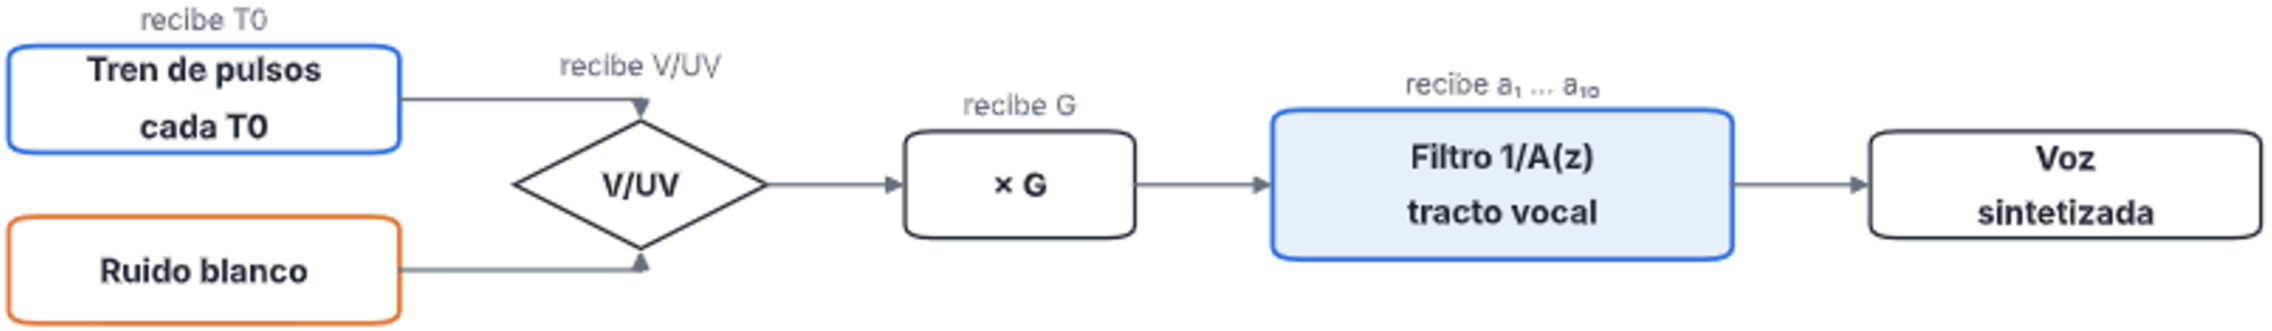

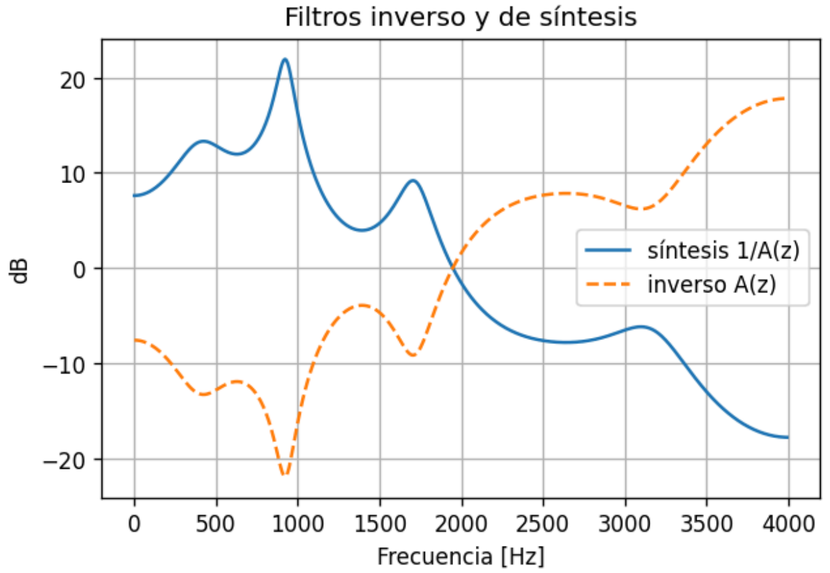

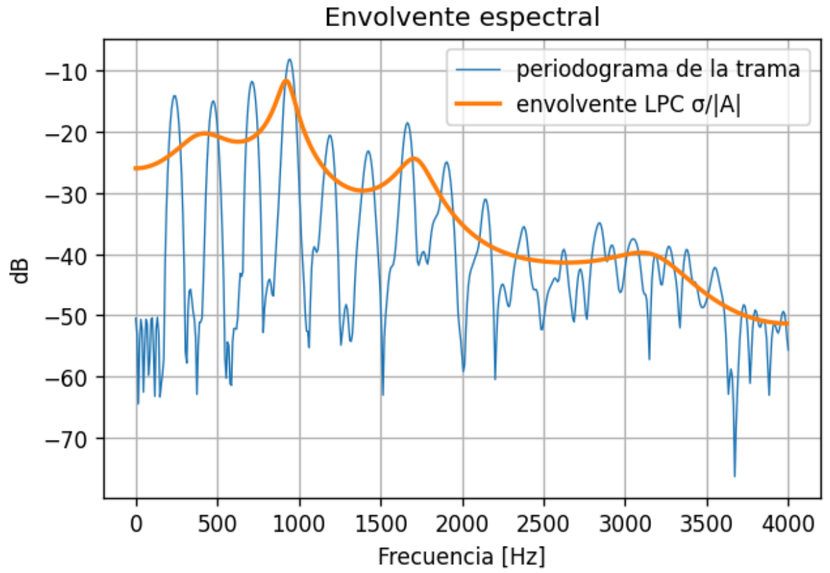

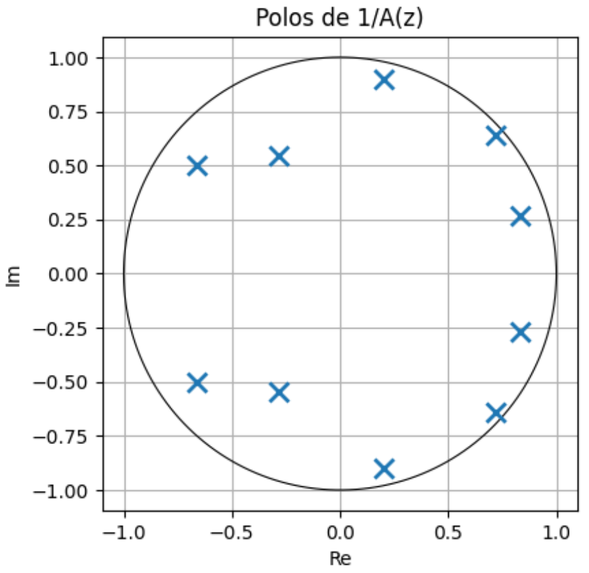

MÉTODOS DE ESTIMACIÓN

Se compararon tres métodos para estimar la frecuencia fundamental (F0 o pitch) y clasificar las señales en sonoras (V) y sordas (UV).

Autocorrelación del residuo LPC

Busca patrones que se repiten en la señal para estimar el período fundamental.

Cepstrum

Identifica picos en la señal cepstral que permiten estimar la periodicidad de la voz.

Algoritmo YIN

Utiliza una función de diferencia para encontrar el período fundamental de la señal.

REFERENCIA Y MÉTRICAS DE EVALUACIÓN

Referencia: EGG (laringógrafo)

Registra la actividad de los pliegues vocales durante la producción de la voz.

Se utilizó como referencia para evaluar las estimaciones de pitch y sonoridad.

Métricas utilizadas

VDE: porcentaje de errores en la clasificación sonoro/sordo.

GPE: porcentaje de estimaciones de pitch con errores grandes.

FPE: mide la precisión del pitch en las estimaciones que no presentan errores grandes

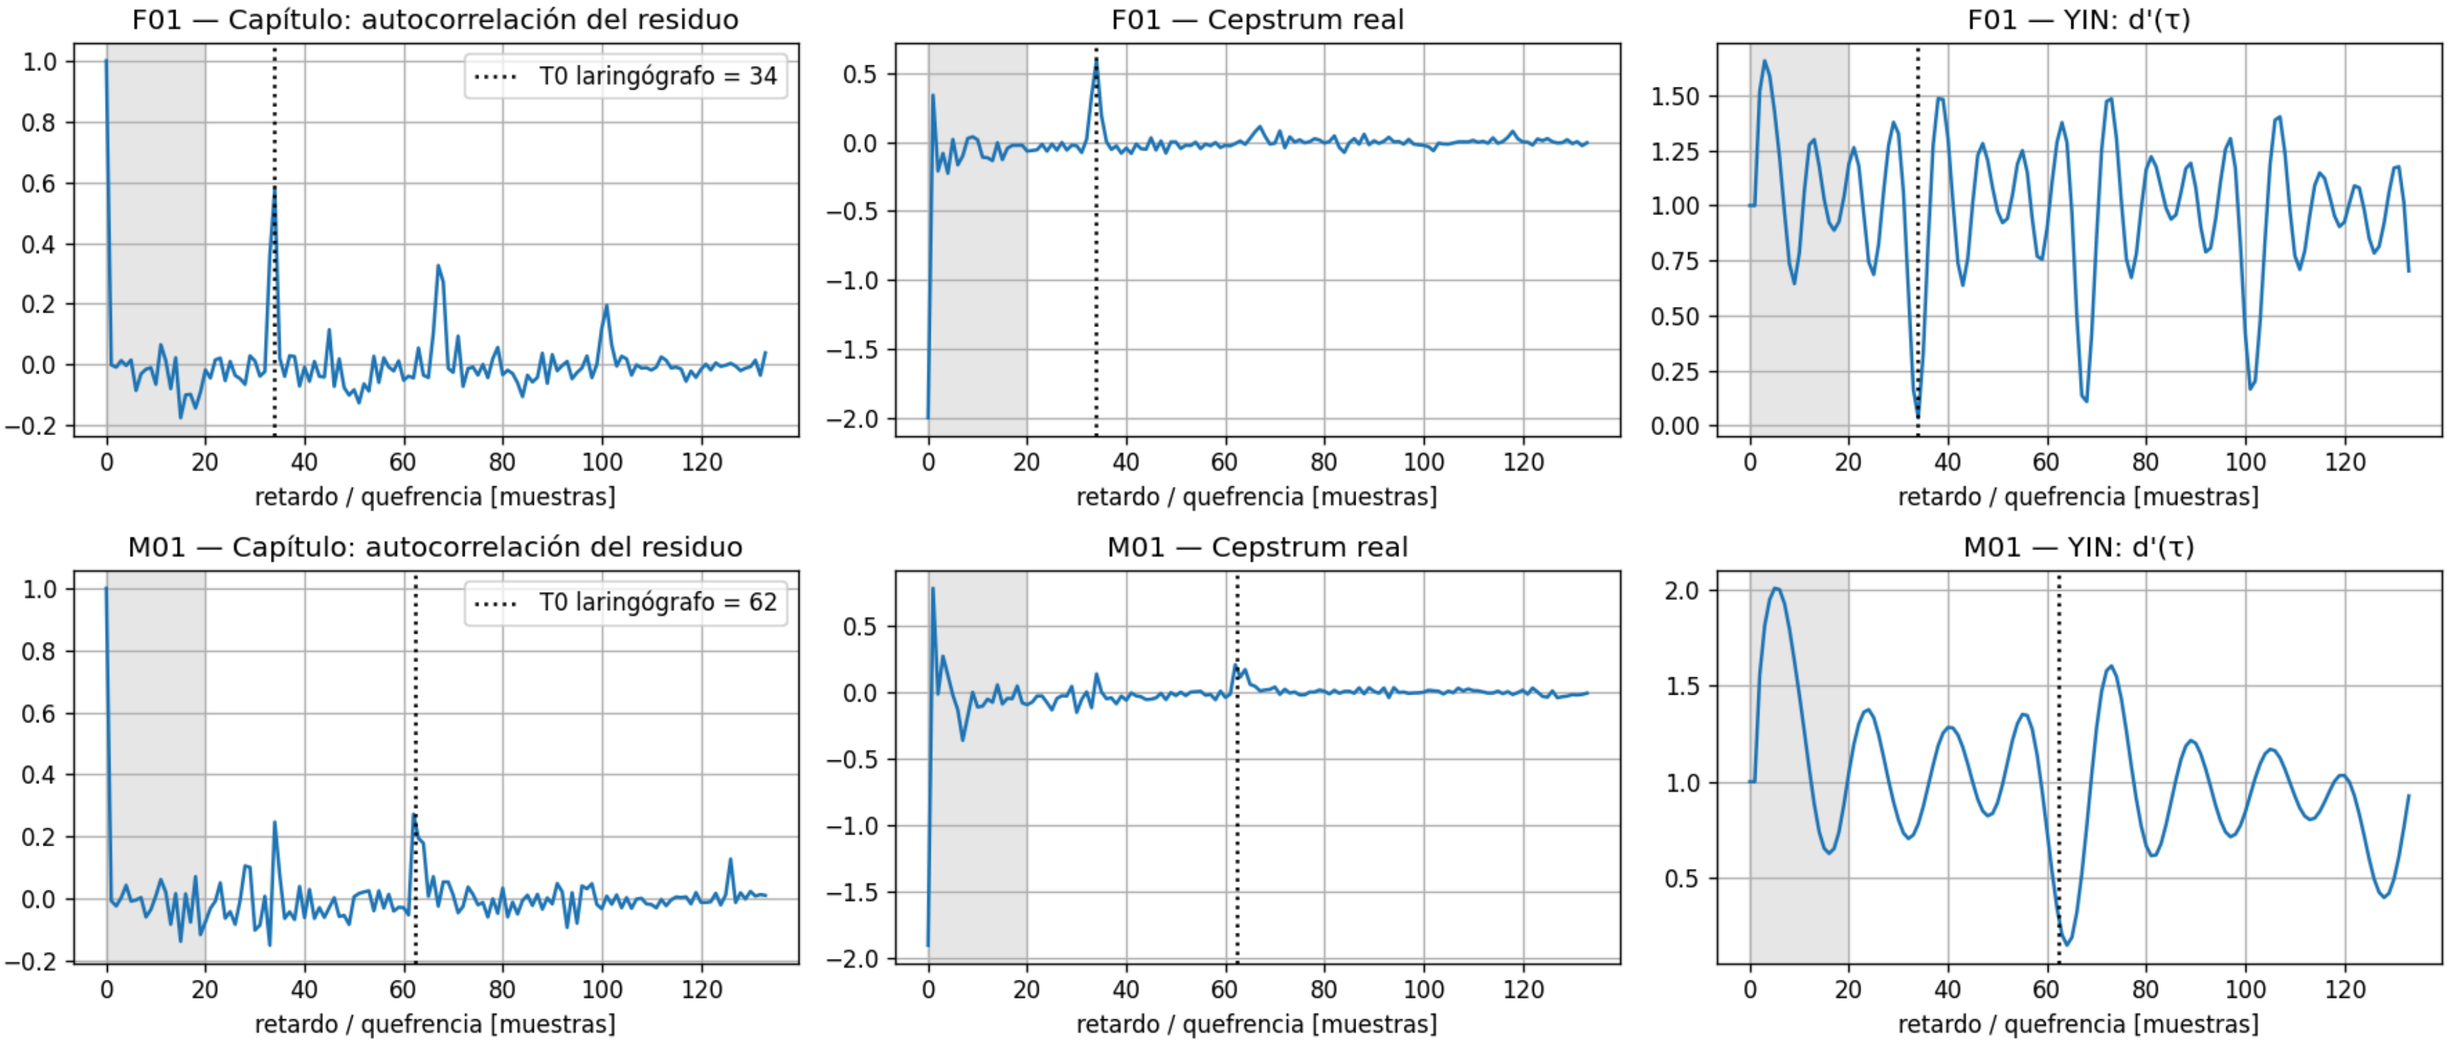

Función donde cada método busca T0 en una trama sonora de F01 (arriba, T0 = 34 muestras) y de M01 (abajo, T0 = 62). La línea punteada es el T0 del laringógrafo y la zona gris, los retardos fuera del rango de búsqueda

RESULTADOS

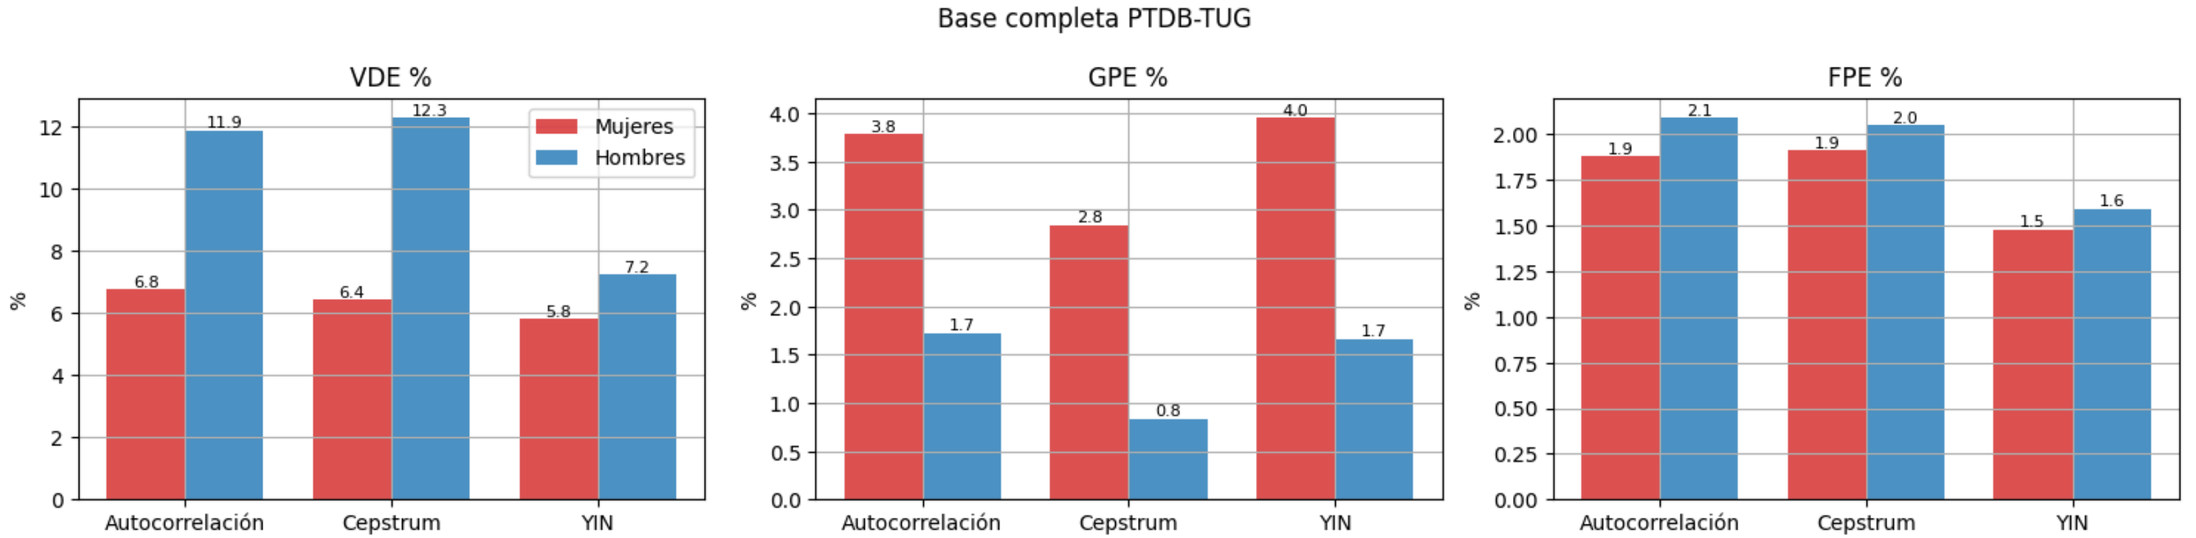

VDE · decisión sonoro/sordo

YIN: 5,8 % mujeres · 7,2 % hombres

GPE · errores grandes de pitch

Cepstrum: 2,8 % mujeres · 0,8 % hombres

FPE · precisión

YIN: 1,5 % mujeres · 1,6 % hombres

YIN

Decide mejor si hay voz y es el más preciso al acertar, en ambos sexos.

Autocorrelación

No es el mejor en ninguna métrica. Mismo ranking que con 200 grabaciones.

Cepstrum

El que menos errores gruesos comete.

RESULTADOS - LOS TRES MÉTODOS CONTRA EL LARINGÓGRAFO

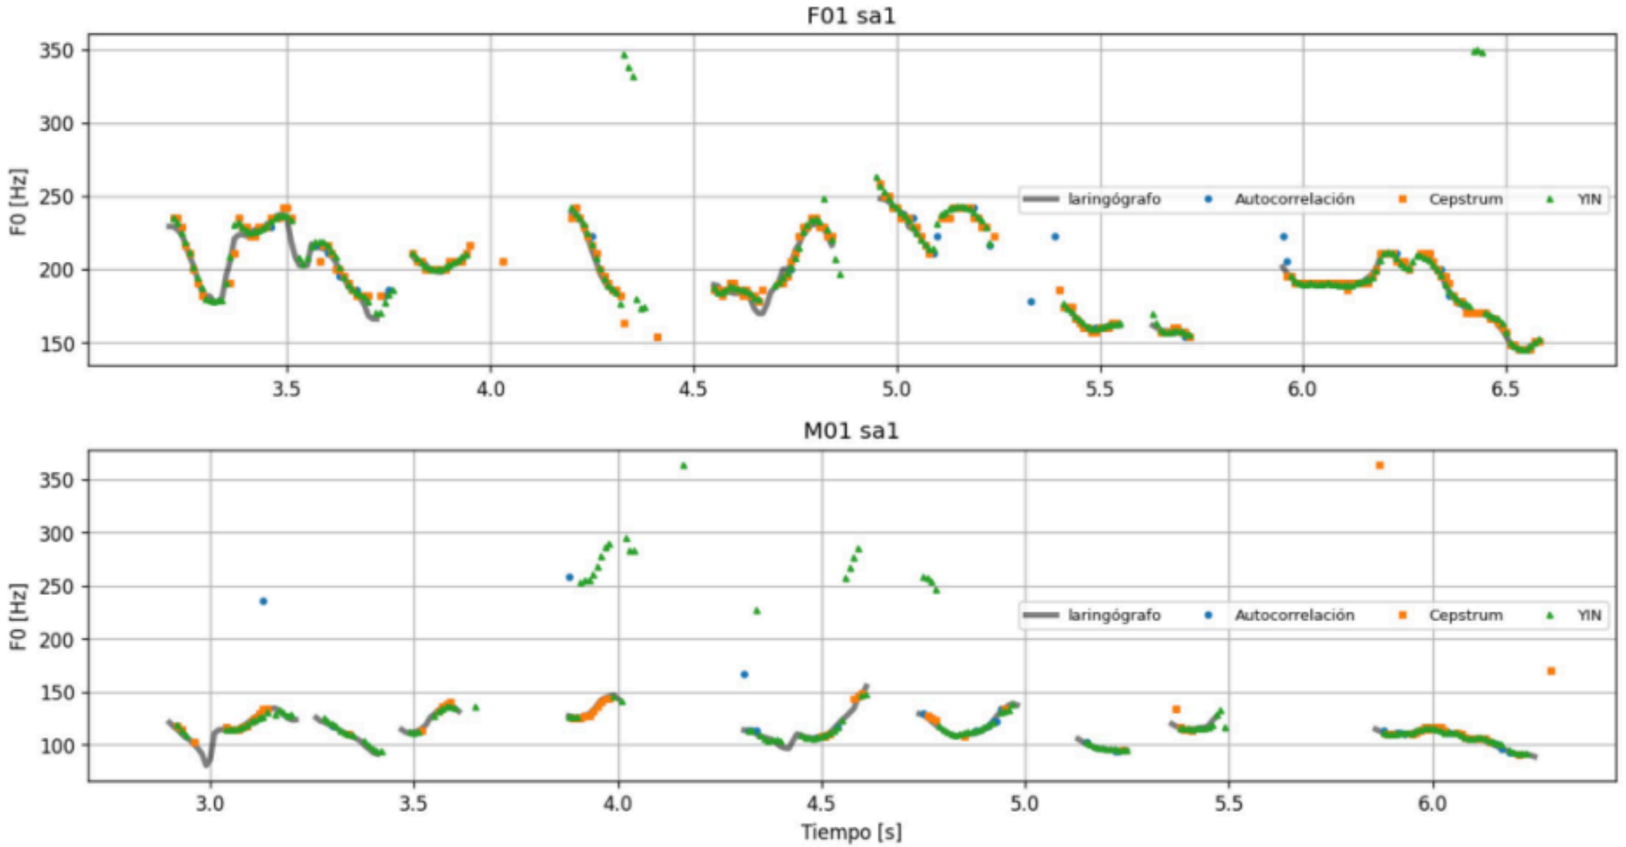

Análisis de los errores de los 3 métodos en el seguimiento de la frecuencia fundamental de una frase real.

RESULTADOS - LAS VOCES GRAVES ENGAÑAN

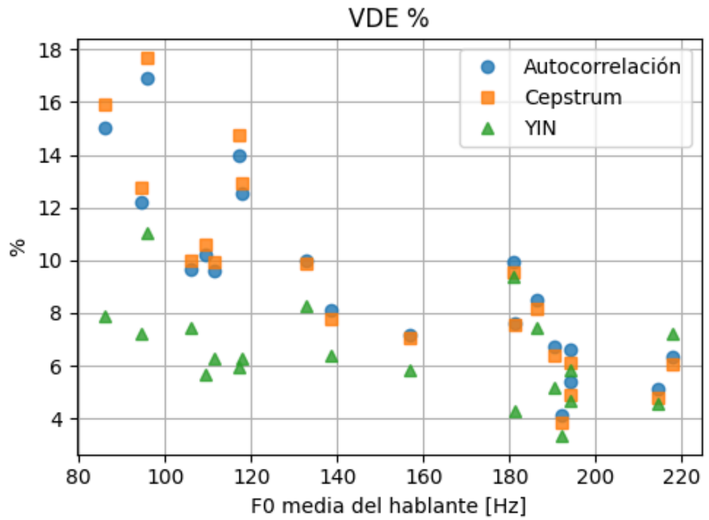

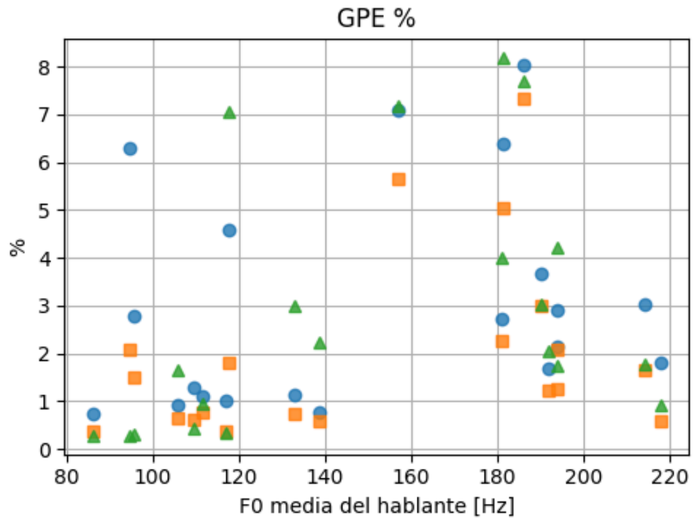

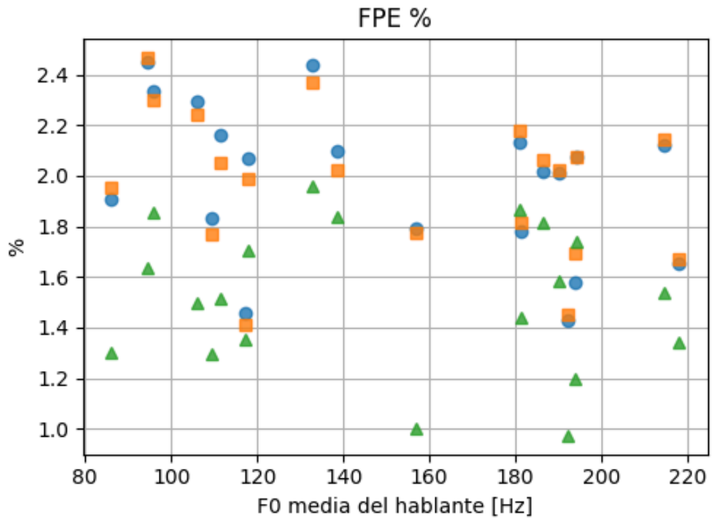

Autocorrelación

M03: F0 = 86 Hz → T0 ≈ 93 muestras, solo 2,6 períodos en 30 ms. En τ = 93 se suman 147 productos contra 240 en τ = 0: el pico baja aunque la voz sea periódica.

Cepstrum

Armónicos cada 86 Hz, pero el lóbulo principal de la ventana de Hamming de 240 muestras mide ≈ 133 Hz: no los resuelve y el pico cepstral cae.

YIN

Compara siempre 240 muestras con su copia desplazada: el puntaje no se penaliza. VDE en hombres: 11,9 % → 7,2 %.

RESULTADOS - CADA PUNTO ES UN HABLANTE

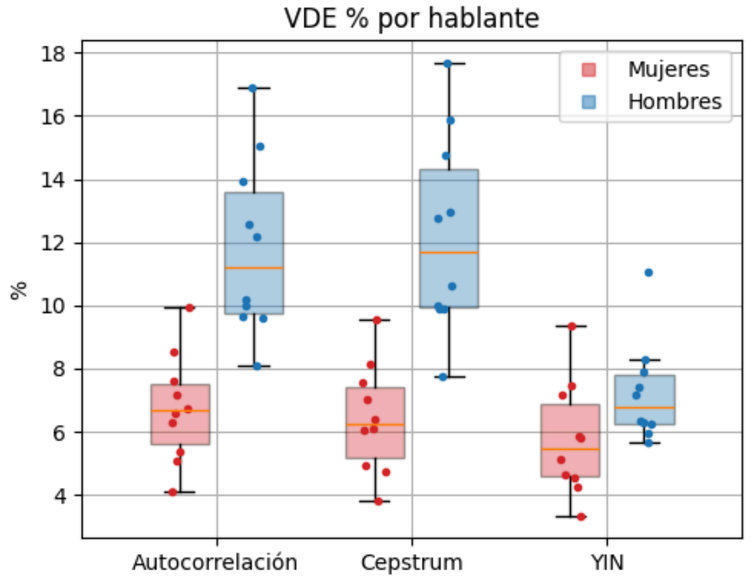

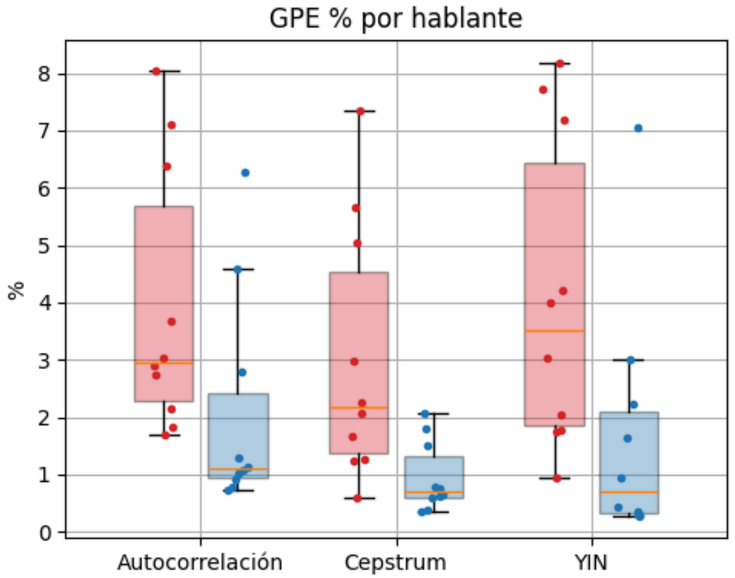

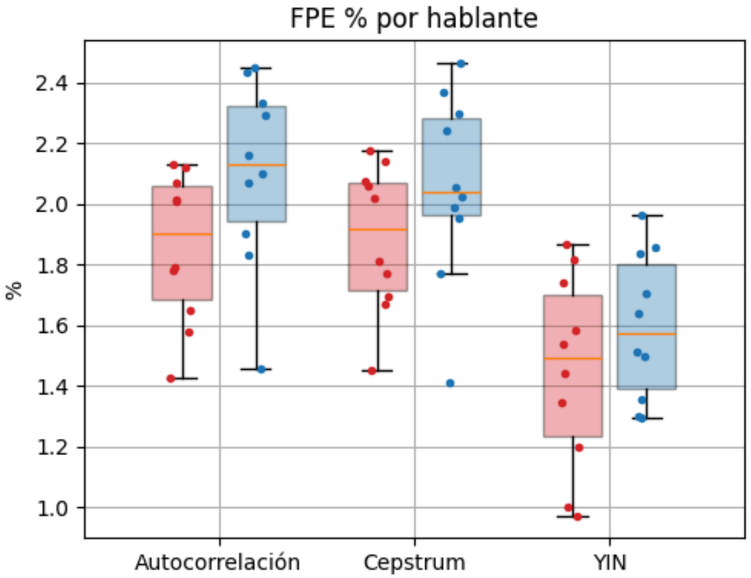

YIN también es más parejo

Baja el VDE de los hombres y también su dispersión: desvío entre hablantes de 1,6 puntos contra 2,8 y 3,1.

Algunas mujeres engañan a los tres

Los GPE altos (5 a 8 %) se repiten en F06, F08 y F10 con los tres métodos: mujeres con tramos muy graves, compatibles con voz creaky.

RESULTADOS - ERRORES DE OCTAVA Y CONSISTENCIA

¿Hacia dónde se equivocan?

% de errores gruesos	Octava arriba	Octava abajo
Autocorrelación · mujeres	42 %	45 %
Cepstrum · mujeres	51 %	34 %
YIN · mujeres	71 %	19 %
YIN · hombres	81 %	8 %

La advertencia del capítulo (octava arriba en mujeres) se cumple, pero la octava abajo pesa igual. YIN casi siempre sube: es el costo de tomar el primer mínimo.

Wilcoxon pareado por hablante

Comparación	Hablantes	p
YIN mejor VDE que autocorrelación	19 de 20	$3 \cdot 10^{-5}$
YIN mejor FPE que autocorrelación	20 de 20	$2 \cdot 10^{-6}$
Cepstrum mejor GPE que autocorrelación	20 de 20	$2 \cdot 10^{-6}$
YIN vs autocorrelación en GPE	11 de 20	0,99 (n. s.)

Las ventajas principales se repiten en casi todos los hablantes ($\alpha = 0{,}05$).

NINGÚN MÉTODO GANA EN TODO

ALGUNOS AUDIOS

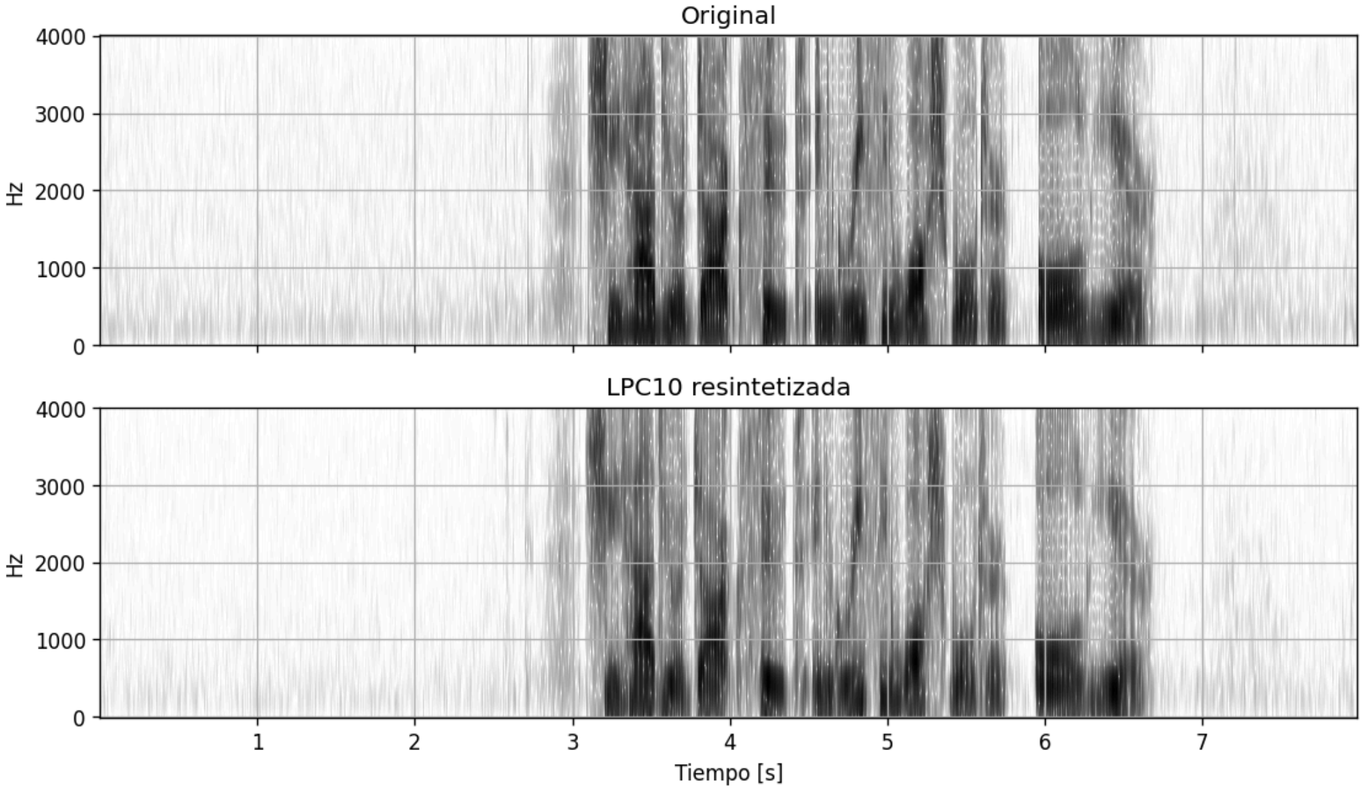

ORIGINAL F

ORIGINAL M

LPC10 F

LPC10 M

LARINGÓGRAFO F

LARINGÓGRAFO M

Las voces reconstruidas con los tres métodos y con la referencia de pitch del laringógrafo resultaron muy similares entre sí.

CONCLUSIÓN

- Se logró implementar el sistema LPC10 para analizar y reconstruir señales de voz.
- YIN fue el método con mejor desempeño general, al presentar menores errores en la clasificación sonoro/sordo y mayor precisión en el pitch.
- El cepstrum obtuvo los mejores resultados en la detección de errores gruesos de pitch.

La calidad de la voz reconstruida también está limitada por el propio modelo de excitación de LPC10.

UNER Facultad de Ingeniería

¡GRACIAS POR SU ATENCIÓN!